自然言語処理

Natural Language Processing

授業URL: https://shibaura-it.zoom.us/j/96136065393

第2回　2026/10/8

芝浦工業大学 工学部
杉本　徹
sugimoto@shibaura-it.ac.jp

前回のミニ課題 回答まとめ

システムの種類	使用率	満足率	満足／不満足の理由
かな漢字変換 （例：MS IME）	100%	69%	○ 変換精度が高い ○ 学習機能や予測変換が便利 × 名前・専門用語・文脈考慮に課題
検索エンジン （例：Google）	100%	75%	○ 欲しい情報が素早く得られる ○ 不完全な入力にも対応 △AI回答精度 × 不要なページや広告が多い
機械翻訳 （例：Google翻訳）	99%	62%	○ 大体正しい．手軽に利用できる △ 誤訳や不自然な訳も／gPBLで利用 × 専門用語の訳や文脈考慮に課題
音声入力・応答 （例：Siri）	68%	35%	○ 大体認識される．便利 × 音声認識の精度が低い，周りの音 × 手の操作の方が早い．誤作動する
AIチャット （例：ChatGPT）	99%	72%	○ 様々な分野に対応し回答してくれる ○ 情報のまとめ，プログラミングに有用 × 誤情報，信用できない，意図のずれ

授業計画

	授業計画	課題出題予定
導入	1．自然言語処理の概要	ミニ課題
	2．日本語文法とコーパス	課題1（コーパス検索）
	3．機械学習	課題2（分類実験）
基礎技術（言語解析）	4．形態素解析（1）解析手法	
	5．形態素解析（2）コスト推定	課題3（MeCab実験）
	6．構文解析	
	7．意味解析（1）単語の意味	課題4（WordNet検索）
	8．意味解析（2）文の意味	

授業計画（続き）

	授業計画	課題出題予定
応用技術	９．情報検索，文書分類	課題５（文書分類実験）
	１０．機械翻訳，対話システム	
深層学習	１１．RNN，Transformer	課題６（機械翻訳実験）
	１２．BERT，GPT	
	１３．大規模言語モデル	課題７（LLM実験）
	１４．まとめと今後の展望	

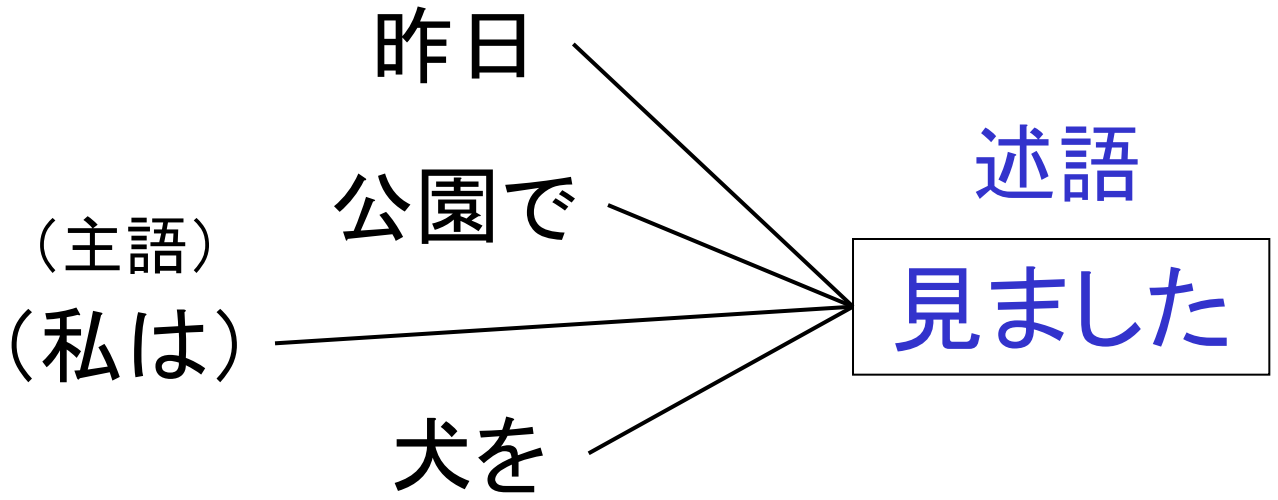
- 課題２～７は，簡単なプログラムを作って実行し，実行結果をレポートにまとめる．
  - 使用するプログラミング言語は自由
  - Pythonで作る人向けのヒント（複雑な問題は見本プログラム）を提供

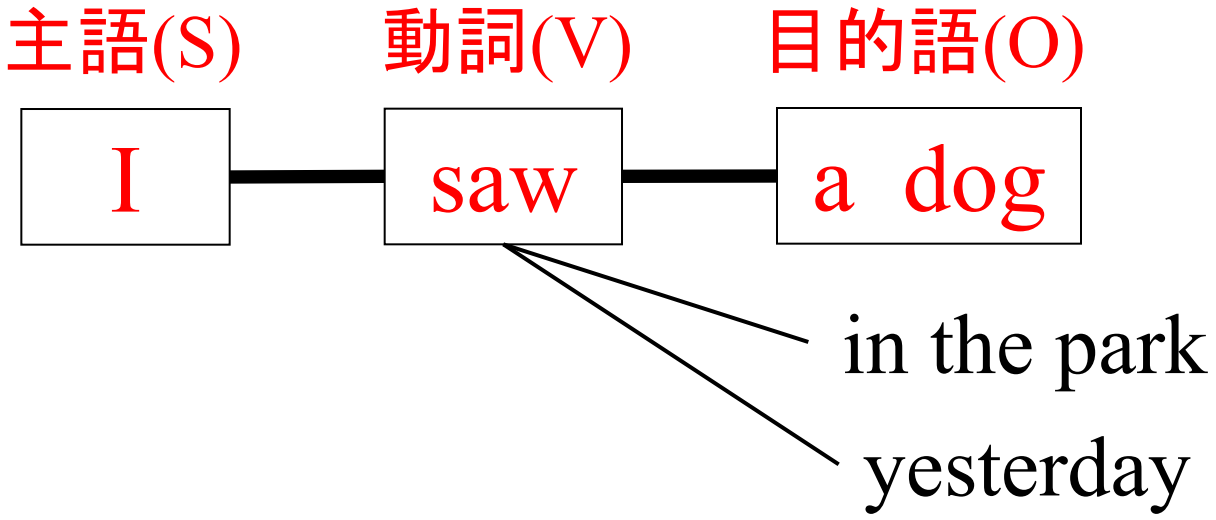
今日の内容

- 日本語文法とコーパス
  - 文の構造
  - 単語，品詞
  - コーパス

  - 第1回課題：コーパスを使ってみよう
    提出期限：10/14（水）

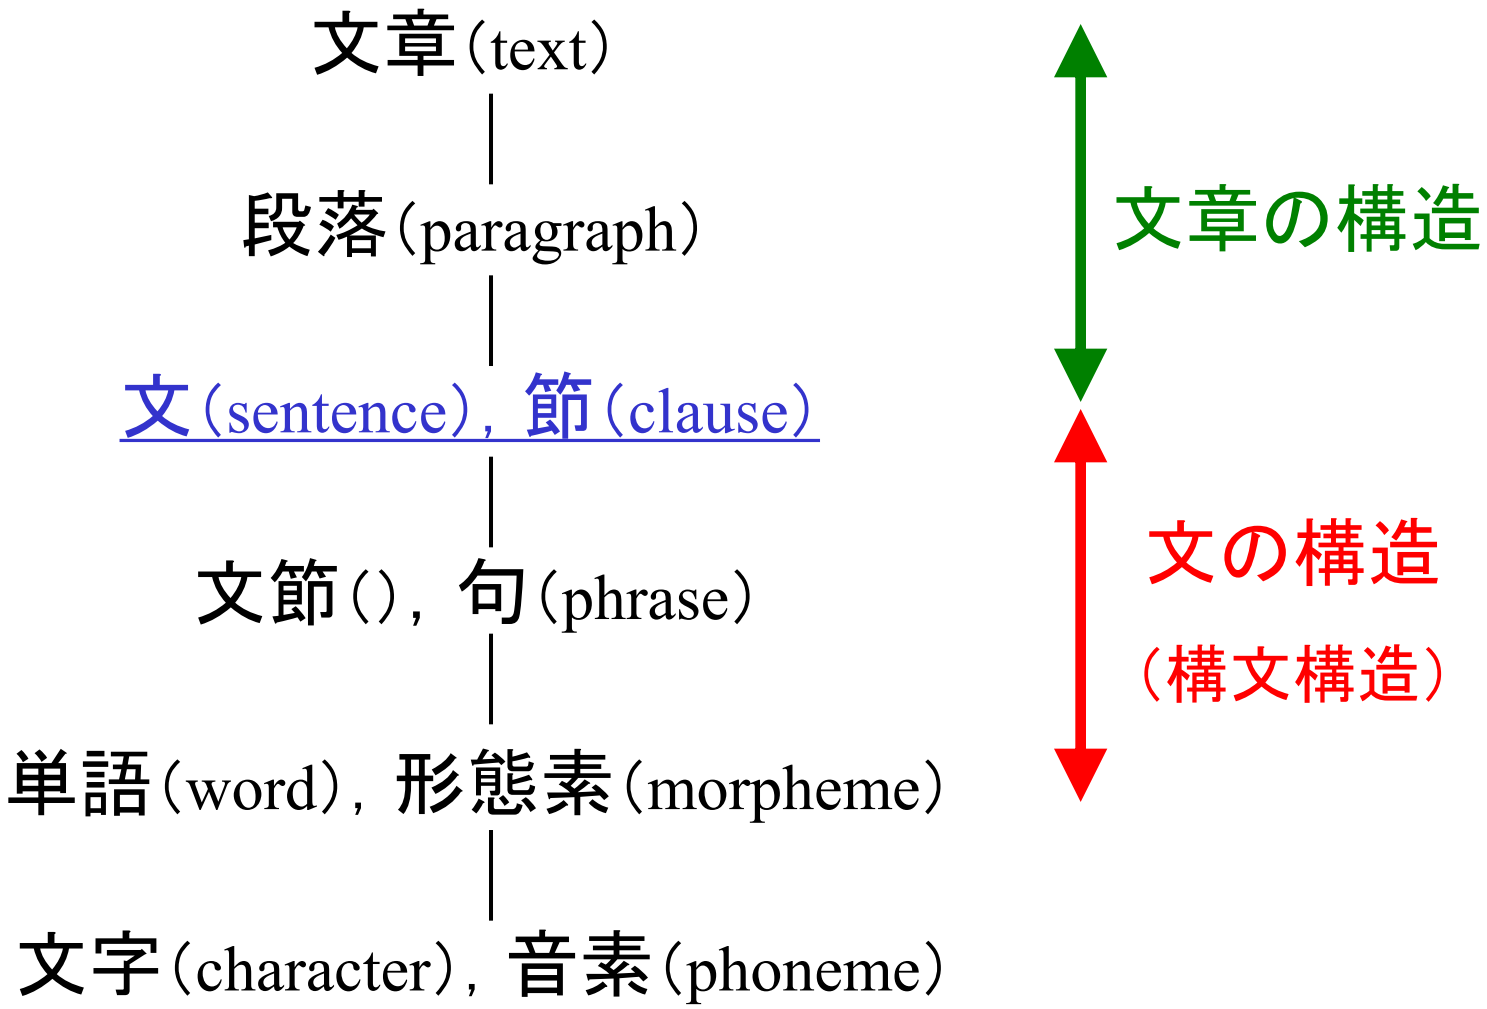
日本語の特徴（英語との比較）





文の構造

文章，文の階層構造


文章（text）
段落（paragraph）
文（sentence），節（clause）
文節（），句（phrase）
単語（word），形態素（morpheme）
文字（character），音素（phoneme）
文章の構造
文の構造
（構文構造）

- 文（sentence）
  - 完結した表現内容を表す最小の単位
  - 通常，「。」，「？」などで終わる

- 節（clause）
  - 文の一部分で，主語・述語を持つもの
  - １つの文の中に複数の節が含まれることがある
  - 例：「雨が降ってきたので，太郎は傘をさした。」
    副詞節
  - 例：「花子は，昨日借りた本を読んだ。」
    連体節

- 句（phrase）
  - 一つの意味を表す単語のまとまり

    例：名詞句 「古い本」 “an old book”

    「昨日買った本」

    “the book that I bought yesterday”

    例：前置詞句 “in the morning”, “at the moment”

    例：後置詞句 「私が」「古い本を」

- 文節
  - 文を読むとき，区切っても不自然にならないような最小の単位
  - 自立語（名詞や動詞）＋付属語（助詞や助動詞）

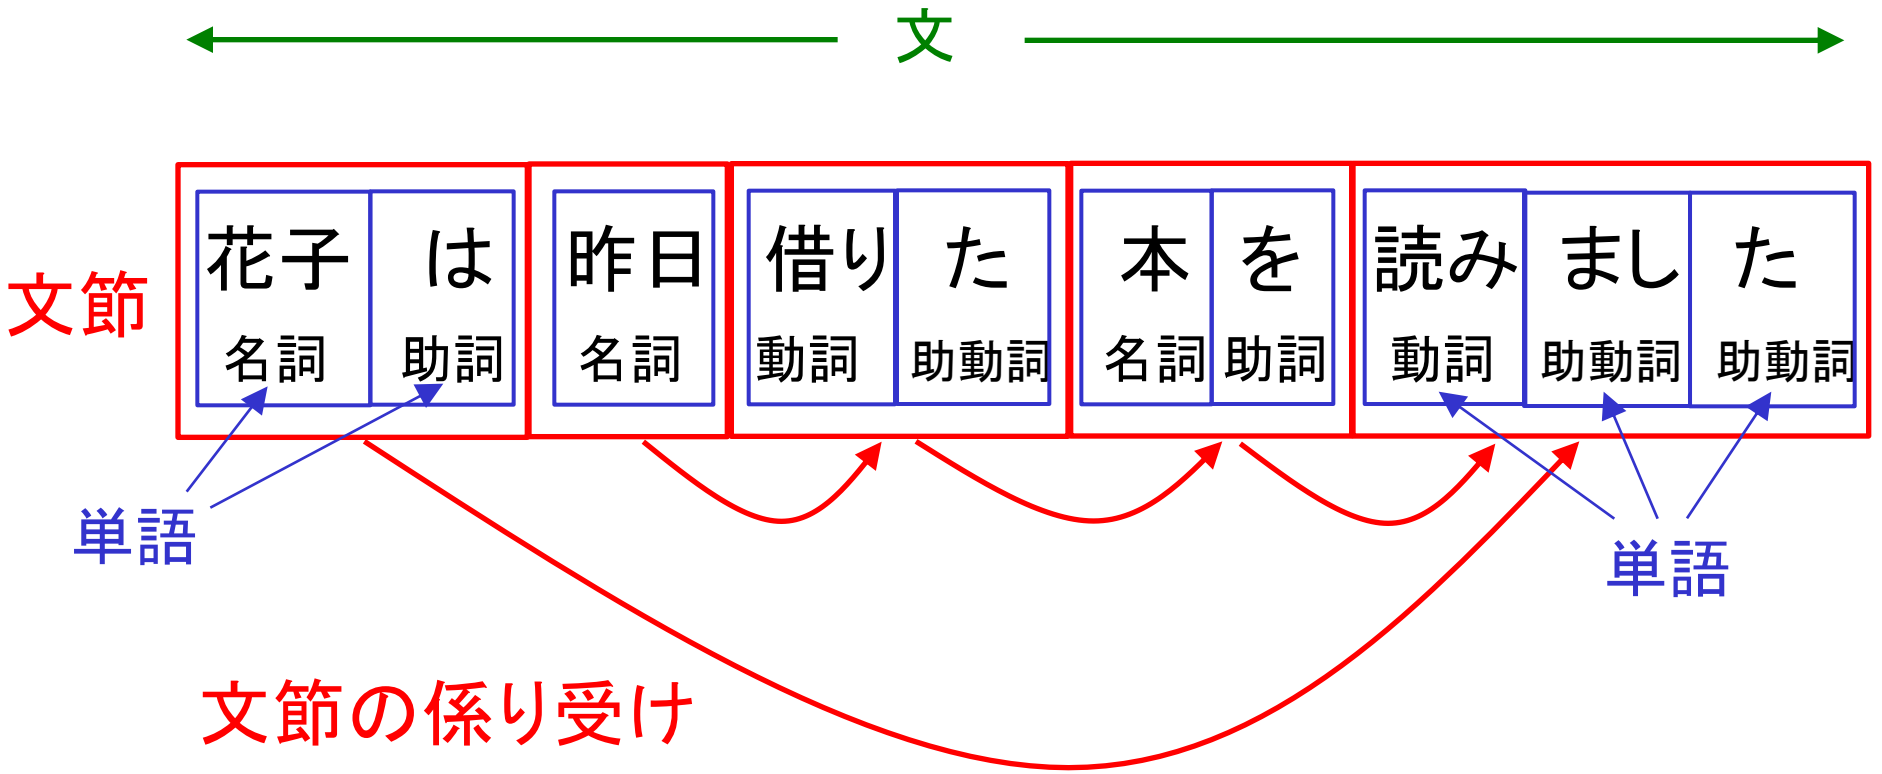
    （付属語は 0個，1個または複数個）

- 単語（word）
  - まとまった意味・機能をもつ最小の単位
  - 国語辞典の見出しに相当する

- 形態素（morpheme）
  - 意味をもつ最小の単位
  - 単語とほぼ一致するが，以下の例外がある

    接尾辞 “-ing” “-est” 「屋」「さん」などは，形態素だが単語ではない

文，文節，単語の例


文
文節
花子
名詞
は
助詞
昨日
名詞
借り
動詞
た
助動詞
本
名詞
を
助詞
読み
動詞
まし
助動詞
た
助動詞
単語
単語
文節の係り受け

文の基本構造

1. 動詞文 「(名詞) が (動詞)」

   例:「鳥 が さえずる。」

2. 形容詞文 「(名詞) が (形容詞)」

   例:「風 が 強い。」

3. 名詞文 「(名詞) が (名詞) だ」

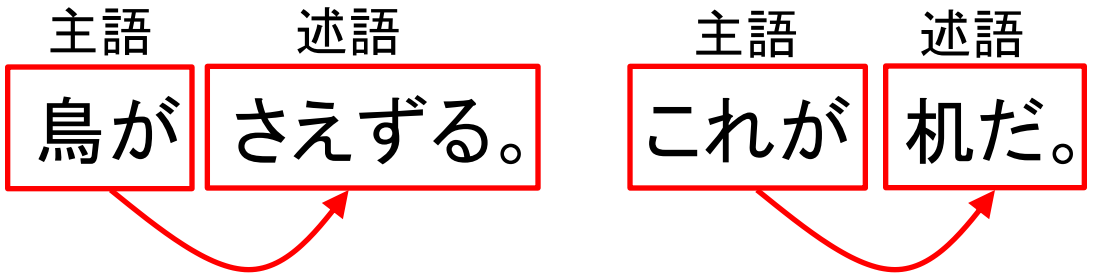
   例:「これ が 机 だ。」

上記の文で「(名詞)が」の部分 ⇒ 主語
「が」より後の部分 ⇒ 述語
} と呼ぶ

文節と文節の関係

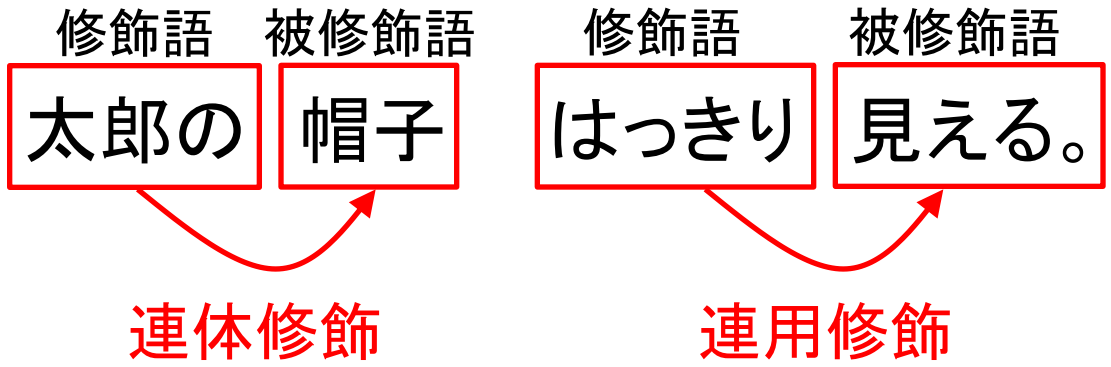
- 主語･述語の関係

例：



- 修飾･被修飾の関係

例：



単語，品詞

単語の種類と品詞

- 自立語（文節の先頭にくる単語）
  ＝ 内容語（具体的な意味内容をもつ単語）
  - 動詞，形容詞，形容動詞
  - 名詞，副詞，連体詞，接続詞，感動詞

- 付属語（自立語の後に付属して使われる単語）
  ＝ 機能語（文において文法的な機能を表す単語）
  - 助動詞
  - 助詞

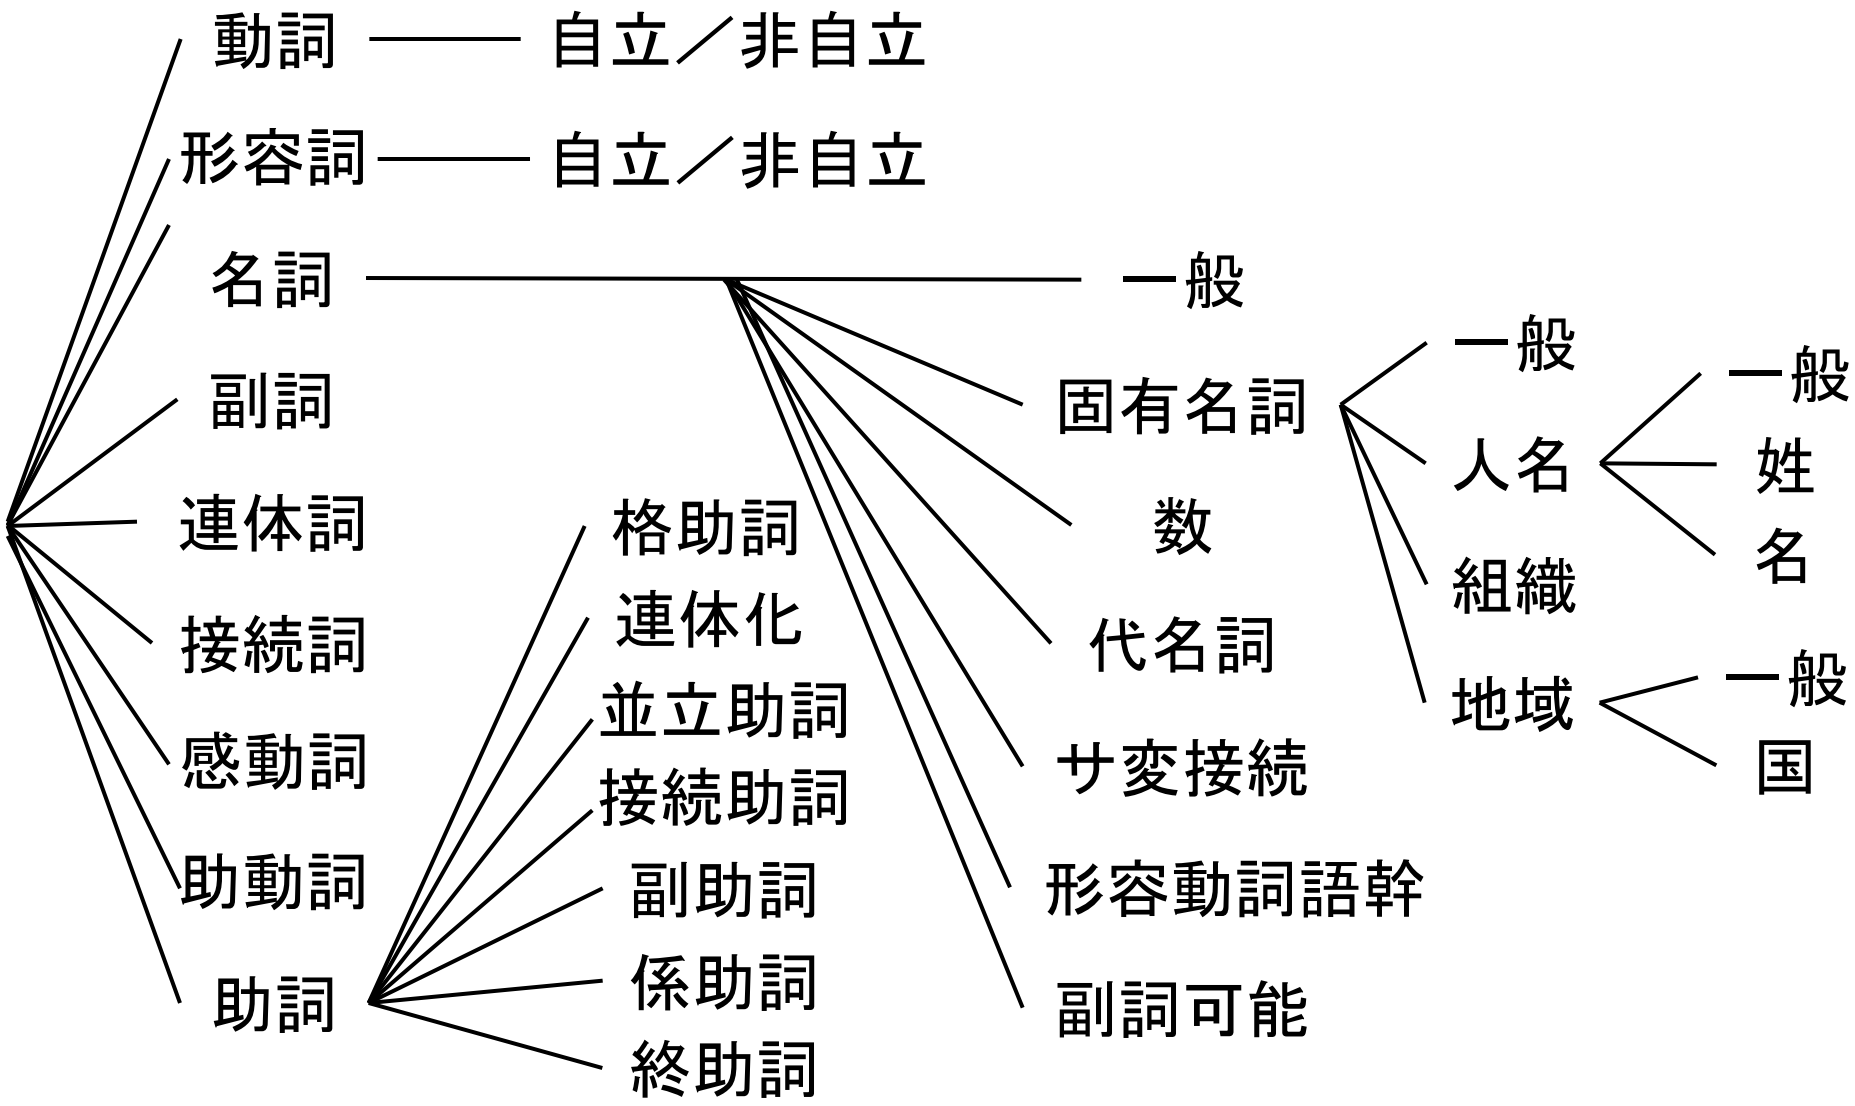
品詞分類表

単語	自立語	活用あり	述語になる（用言）	動詞
				形容詞
				形容動詞
		活用なし	主語になる（体言）	名詞
			連用修飾語になる	副詞
			連体修飾語になる	連体詞
			接続語になる	接続詞
			独立語になる	感動詞
	付属語	活用あり		助動詞
		活用なし		助詞

参考：形態素解析，辞書，品詞体系

- 形態素解析
  - 文を単語列に分解し，各単語の品詞を求める処理
- 単語辞書の例：IPA辞書（ipadic）
  - 代表的な形態素解析ツールChaSen, MeCab で用いられる単語辞書
  - 各単語の品詞情報は，IPA品詞体系にしたがって記述
- IPA品詞体系
  - 階層的な分類構造をもった，日本語の品詞体系

品詞体系の例: IPA品詞体系



参考：品詞分類に関するデータ例

			単語辞書(*1)に格納された単語数／割合		コーパス(*2)内での延べ出現回数／割合	
自立語	活用あり	動詞	14,922	6%	286万	12%
		形容詞	1,824	0.7%	23万	1%
		形容動詞	3,328	1%	27万	1%
	活用なし	名詞	224,898	90%	1125万	49%
		副詞	3,032	1%	19万	0.8%
		連体詞	135	0.05%	9万	0.4%
		接続詞	171	0.07%	7万	0.3%
		感動詞	252	0.1%	1万	0.05%
付属語	活用あり	助動詞	199	0.08%	145万	6%
	活用なし	助詞	237	0.1%	671万	29%

（*1）IPA辞書　（*2）2012年の毎日新聞全記事の本文

自立語（1）活用がある自立語（用言）

- 活用：後ろにくる言葉に応じて語形が変わること
  （未然形，連用形，終止形，連体形，仮定形，命令形）
- 用言は，後ろに助動詞や助詞を伴い，述語を形成する

- 動詞（ウ段で終わる）
  - 事物の動作・作用・存在を表す　例：「食べる」，「吹く」，「ある」
  - サ変動詞　例：「勉強する」，「印刷する」，「決定する」
- 形容詞（「い」で終わる．「イ形容詞」ともいう）
  - 事物の性質・状態を表す　例：「美しい」，「高い」，「うれしい」
- 形容動詞（「だ」で終わる．「ナ形容詞」ともいう）
  - 事物の性質・状態を表す　例：「静かだ」，「まじめだ」，「好きだ」

自立語(2) 名詞

- 物事の名前や数などを表す
- 「が」,「は」などの助詞を伴って主語になる
- 名詞の種類
  - 普通名詞(同類の事物をまとめて呼ぶ)「犬」,「鉛筆」,「海」,「心」
  - 固有名詞(ただ1つしかない固有なものを表す) 地名, 人名, 組織名
  - 数詞(数量や順序などを表す)「1人」,「2つ」,「3日」
  - 代名詞(人や物事の名前の代わりに使う指示語)「私」,「これ」,「だれ」
  - 形式名詞(本来の意味を失い, 形式的に用いられる)「こと」,「ところ」
  - サ変接続(後ろに「する」を付けると動詞になる)「勉強」,「決定」
  - 形容動詞語幹(後ろに「だ」を付けると形容動詞になる)「健康」
  - 副詞的名詞(述語に直接係ることが可能)「今日」,「10月」

自立語(3) その他

- 副詞
  - 用言(動詞，形容詞，形容動詞)を修飾する
  - 例:「はっきり(と)」,「とても」,「もっと」,「たぶん」,「もし」
- 連体詞
  - 名詞を修飾する　例:「この」,「あらゆる」,「大した」
- 接続詞
  - 文と文の間や，文節と文節の間に使われ，前後のつながりの関係を示す　例:「だから」,「しかし」,「かつ」,「または」,「そして」
- 感動詞
  - 話し手の感動や呼びかけ，応答などを表す 「はい」,「こんにちは」

付属語(1)　助動詞

- 用言などの語の後ろに置かれ，いろいろな意味を添える
  - 例:「見ら れ たく ない ようだっ た そうです」
- 助動詞の種類
  - 受身・可能・自発・尊敬 「れる(られる)」
  - 使役 「せる(させる)」
  - 打消 「ない」,「ぬ」
  - 過去・完了 「た(だ)」
  - 推量・意志・勧誘 「う」,「よう」,「らしい」,「まい」
  - 希望 「たい」,「たがる」
  - 丁寧 「ます」
  - 断定 「だ」,「です」
  - 比況 「ようだ(ようです)」,「みたいだ(みたいです)」
  - 伝聞・様態 「そうだ(そうです)」

付属語(2) 助詞

- 様々な語の後ろに置かれ，その語と係り先の語の関係を示したり，その語に意味を添えたりする
- 助詞の種類
  - 格助詞：名詞に付き，その名詞の役割を示す
    例：「が」(主語)，「の」，「を」，「に」，「と」，「で」
  - 接続助詞：用言に付き，前後のつながりの関係を示す
    例：「ば」，「ても」，「が」(逆接)，「から」(理由)
  - 副助詞：様々な語に付き，特定の意味を添える
    例：「は」(主題)，「も」，「さえ」，「まで」，「だけ」
  - 終助詞：主に文末に置かれ，特定の意味を添える
    例：「か」(疑問)，「な」(禁止)，「ね」(念押し)

「が」と「は」の違い

- 格助詞「が」
  - 現象を記述する文において，動作や状態の主体となる語に付ける（主格）
- 副助詞「は」（係助詞，提題助詞ともいう）
  - 用法1．文の主題（theme, topic）を提示する

    主題は旧情報（話し手聞き手双方に了解済みの情報）

    例：「昔おじいさんがいました。おじいさんは山に行きました。」

    主題：旧情報　　新情報
  - 用法2．他のものと対比する

例：「前期は代数は不合格だった。」 vs 「代数は前期は不合格だった。」

参考：主語廃止論（三上章）

- 英文法から輸入した「主語ー述語」の考え方は，日本語において必ずしも必要でない
  - 「象は鼻が長い。」
  - 「僕はウナギだ。」
- 主格（「が」），主題（「は」）の考え方があれば十分

確認問題（１）

- 次の①～③の中で 文（sentence）はどれか？

①「涼しい秋の朝」

②「今から学食に行ってランチを食べよう」

③「昔おじいさんとおばあさんがいました。おじいさんは山へ行きました。おばあさんは川に行きました。」

確認問題（2）

- 「今日は暖かく感じますね」という文を単語に分割し，各単語の品詞を答えなさい．

今日は暖かく感じますね

※形態素解析ツールを用いると自動的に文を単語に分割できる

確認問題（2）続き

- 「今日は暖かく感じますね」という文を単語に分割し，各単語の品詞を答えなさい．また，この文に含まれる文節をすべて挙げなさい．

今日は暖かく感じますね

※係り受け解析ツールを用いると，文節への分割と
文節間の係り受け関係の認識が行える

コーパス

コーパス（Corpus）

- 実際に書かれた言葉や話された言葉を集めた大規模な言語データ
- コーパスの種類
  - 生コーパス：収集したままの文章データ（付加情報なし）
  - タグ付きコーパス：分析に役立つ情報（単語の品詞や読み，構文・意味構造など）を生コーパスに付加したもの
  - 均衡コーパス：複数のジャンルの文章からサンプリングして統合
  - 個別用途のコーパス：学習者コーパス，模擬対話コーパスなど
  - パラレルコーパス：複数の言語間の対訳データ
  - 音声コーパス：録音した音声データ（とそれを文字化したデータ）

コーパスの入手方法

- 配布されているコーパスを利用
  - 有償配布（使用契約が必要）
  - 無償配布（Web上で公開） 例：Wikipediaダンプ

- 自分で新たにコーパスを作成
  - 収集実験（アンケート等）を実施する方法
  - Webから集めてくる方法（Web scraping）
    - APIが用意されている場合はそれを利用する
    - Webクローラ（crawler）／ HTML解析，本文抽出

      （収集先のWebサーバに負荷をかけたり，Webサイトに記載されている注意事項に違反したりしないように）

コーパスの例

名称	規模	内容
新聞記事データ	数千万語／年	毎日，読売，朝日など
現代日本語書き言葉 均衡コーパス（BCCWJ）	約1億語	複数ジャンルの文章を収録． 形態素情報付き
日本語話し言葉コーパス	約750万語	学会講演660時間分． 形態素情報付き
EDRコーパス	約20万文	新聞，雑誌など． 形態素・構文・意味情報付き
日英新聞記事対応付けデータ	約18万文	読売新聞とDaily Yomiuriの記事 内の和文と英文の対応付け
Penn Treebank	約100万語	Wall Street Journal の記事に 品詞情報・構文情報を付加
日本語大規模Webコーパス Swallow	約3000億文字	Common CrawlのWebページアー カイブから日本語文を抽出・精錬
参考：Google N-gramデータ	約2550億語	Web上の文から抽出した 単語n-gramデータ（後日説明）

タグ付きコーパスのデータ例（BCCWJ）

<sentence>

<LUW B="B" SL="v" l_lemma="公共工事請け負い金額" l_lForm="コウキョウコウジウケオイキンガク" l_wType="混" l_pos="名詞-普通名詞-一般" >

<SUW lemma="公共" lForm="コウキョウ" wType="漢" pos="名詞-普通名詞-一般" pron="コーキョー">

公共

</SUW>

<SUW lemma="工事" lForm="コウジ" wType="漢" pos="名詞-普通名詞-サ変可能" pron="コージ">

工事

</SUW>

（略）

</LUW>

（略）

</sentence>

パラレルコーパスのデータ例
（日英新聞記事対応データ）

<T ID=“19930710E1TDY03C000010/21" NM="1-1" SCORE="1.710796165">

<J>欧州は、エディンバラにおいて合意され、コペンハーゲンにおいて強化された成長イニシアチブを精力的に実行しつつある。</J>

<E>Europe is carrying out vigorously the Growth Initiative agreed in Edinburgh and strengthened in Copenhagen. </E>

</T>

<T ID=“19930710E1TDY03C000010/71" NM="1-1" SCORE="1.539716548">

<J>我々は、ロシアの経済発展にとって、改善された市場アクセスが重要であることを認識する。</J>

<E>We recognize the importance of improved market access for economic progress in Russia. </E>

</T>

コーパスの利用

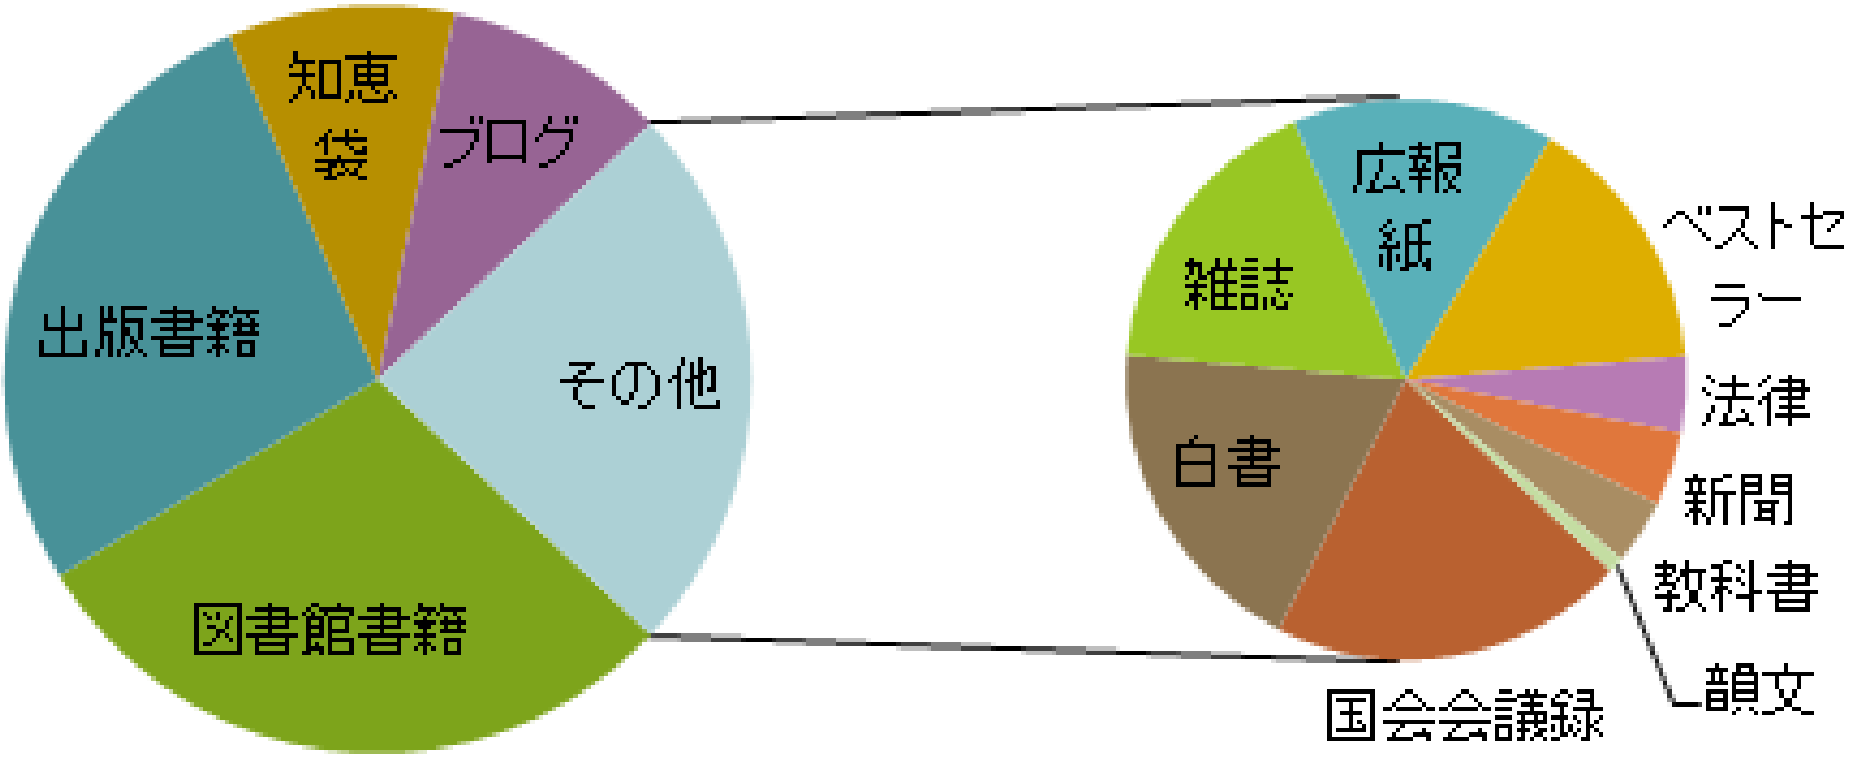
- 言語学的な分析
  - 単語の出現頻度，共起頻度，使用される文脈の調査など（コーパス言語学）
- 統計的な自然言語処理
  - コーパスにタグ付けされた品詞情報や構文情報を正解データとして，それらの情報を生コーパスから自動的に求められるようにする（⇒ 機械学習やパターン認識に基づく形態素解析・構文解析）
  - 文法規則・翻訳規則などの言語知識の自動構築

現代日本語書き言葉均衡コーパス
（BCCWJ: Balanced Corpus of Contemporary Written Japanese）

- 現代日本語の書き言葉の全体像を把握するために国立国語研究所が開発し，2011年に公開
- 多様なジャンルの文章を含む
  - 書籍，雑誌，新聞，ベストセラー，知恵袋，法律，国会会議録，広報紙，教科書，韻文，白書，ブログ
- 形態素情報（品詞，読みなど）を付加
- Web上の検索ツール公開
  - 少納言，中納言（KWICコンコーダンサ）
  - NINJAL-LWP for BCCWJ（レキシカルプロファイラ）

BCCWJ の内訳

（単語数に基づく割合）



全体で約1億語の規模

BCCWJ の収録文の例

書籍	学業、野球の双方に意欲のあった江川卓は、ここで一流大学へ入れる学力を保持しながら野球にはげむ毎日を望んだのである。
雑誌	大学時代に彼女をデートに誘う口実に、“宝塚に行こう”と提案した時から僕のファン歴がスタートしました。
国会会議録	これらの国民的要請にこたえるため、放送を効果的に活用する大学を設置することは、まことに重要な課題であります。
広報紙	財団法人岡山県育英会では、岡山県出身で東京都及びその周辺の大学に入学する男子学生の新入寮生を募集します。
ブログ	わざわざ東京まで行って電機を学ぶ大学に行くのに大丈夫かとオイラは言いたい・・・
知恵袋	社会人入試を受けて大学で心理学を学びたいのですが、関西でお勧めの大学をご存知の方がいらっしゃれば教えてください。

NINJAL-LWP for BCCWJ（略称 NLB）の使いかた

1. Webブラウザで http://nlb.ninjal.ac.jp/ にアクセス
2. 使い方の説明を読む
3. 「検索を開始する」をクリック
4. 調べたい単語をタイプ入力し，「絞り込み」をクリック
5. 見出し，読みなどが表示されるのでクリック
6. 少し待つと，構文パターンごとの出現頻度の表が表示される
7. ここで「グループ別」の右側にある「基本」タブを選択すると，今調べている単語の文章ジャンル別の出現回数とPMW（Per Million Words, 100万語あたりの出現回数）が表示される



頻度（出現回数）

PMW（Per Million Words,
100万語あたりの出現回数）

NLB の使いかた（続き）

8. 「グループ別」または「パターン頻度順」タブに戻り，調べてみたい構文パターンを1つ選択する

9. 画面中央の表に，コロケーションごとの出現回数が表示される

10. コロケーションを1つ選ぶと，画面右側の表に，該当する文のデータが表示される

11. この表の上部には，そのコロケーションの文章ジャンル別のPMWが示されている

- 「？」をクリックすると使い方の説明が表示される


メール
頻度=12,459
パターンごとの
コロケーション
文章ジャンル別
のPMWと実例
グループ別
パターン頻度順
基本
» 助詞+動詞
パターン 頻度 比率
メールが... 1,664
メールは... 423
メールも... 229
メールの... 28
メールを... 2,605
メールに... 518
メールへ... 4
メールで... 1,182
メールと... 35
メールから... 56
メールまで... 14
メールより... 12
動詞 «
パターン 頻度 比率
動詞基本形＋メール 180
動詞連用形＋メール 38
動詞過去＋メール 371
動詞連用形＋て
メールを... 245種類
コロケーション
コーパス全体
頻度 MI LD
メールを送る 554 10.90 10.27
メールをする 267 23.41 11.71
メールをいる 184 11.05 9.91
メールを送信する 99 12.37 9.90
メールを出す 71 6.47 6.01
メールを使う 65 5.69 5.26
メールを見る 62 4.20 3.82
メールをいただく 55 7.98 7.26
メールを受信する 53 12.13 9.13
メールを書く 47 5.74 5.28
メールをくれる 44 9.48 8.12
メールを受け取る 44 8.69 7.67
メールをみる 43 4.91 4.50
メールをもらう 42 7.81 7.04
メールを開く 39 6.52 5.97
メールを読む 35 6.19 5.66
メールをくる 33 11.44 8.45
メールをできる 32 2.79 2.41
メールを打つ 31 6.57 5.97
メールを入れる 28 13.69 8.41
メールを作成する 26 7.52 6.64
メールをしまう 24 9.12 7.48
メールをくださる 22 7.89 6.80
メールを転送する 21 11.27 7.86
メールを送る 全554件
知恵袋: 35.83
ブログ: 4.83
出・書籍: 1.74
教科書: 0.96
広報: 0.73
ベスト: 0.24
メールを送った。
(Yahoo!知恵袋, 2005, Yahoo!知恵袋)
メールを送るしくみ
(斉藤弘子著 『55才からの電子メール入門』, 200
空 メールを送るだけ♪
(Yahoo!ブログ, 2008, Yahoo!ブログ)
メールを送る準備をしよう
(山田祥平, できるシリーズ編集部著 『できるイン
メールを男からよく送る。
(Yahoo!知恵袋, 2005, 恋愛相談、人間関係の悩み)
んで メールを送りました。
(Yahoo!知恵袋, 2005, Yahoo!オークション)
その メールを憬に送った。
(華房憬著 『私-柏木春菜』, 2005, 913)
(普通に メールを送った場合)
(Yahoo!知恵袋, 2005, インターネット)

使用例:「メール」という語の使われ方を調べる

- NLB で「メール」を検索して分かること
  - 「基本」タブの情報から，「メール」という語は知恵袋や広報紙，ブログ，雑誌でよく使われている
  - 「メールを…」という構文パターンで検索すると，多くの文章ジャンルでは「メールを送る」という言い方が最も多いが，教科書では「メールを出す」が多い
  - 「名詞＋メール」という構文パターンでは「ファーストメール」という表現の頻度が高いが，これはすべて知恵袋からのデータである

第１回課題
コーパスを使ってみよう

課題１：単語の出現頻度調査

- NLBを用いて，次の３つの文章ジャンルのうちのどれか１つでの使用頻度（PMW）が他の２つでの使用頻度（PMW）よりも高い単語の例を見つけなさい

  ジャンル１：国会会議録

  ジャンル２：教科書

  ジャンル３：ブログ

- 具体的には，

  a) 議事録でのPMWが教科書およびブログでのPMWより高い単語

  b) 教科書でのPMWが議事録およびブログでのPMWより高い単語

  c) ブログでのPMWが議事録および教科書でのPMWより高い単語

  の例をそれぞれ最低１個ずつ見つけて解答してください

課題2：単語の使われ方調査

- 自分で自由に単語を1つ選んで，NLBを用いて，その単語の使われ方を調査しなさい
- 調査の方法は，前述の「メール」の使われ方調査の例を参考にして，
  - いくつかの構文パターンに対して，特徴的なコロケーションを調べてまとめる
  - 例えば自分の知りたい語 X が名詞の場合，「Xを…」，「名詞＋X」，「名詞のX」などの構文パターンにおいて特徴が出やすいと思われる．この他にも X を形容詞として「X＋名詞」，X を動詞として「副詞＋X」など，色々な調べ方が考えられる
  - 文章ジャンルによる違いも考察するとよい

レポートの形式，期限，提出方法

- 形式：電子ファイル（PDF形式）
- 内容構成：レポートの内容に，下記の①②③を（それぞれの課題について）含めること
  - ①調査方法の説明
  - ②調査結果（必要に応じて表やグラフを用いる）
  - ③結果についての考察
- 期限：10月14日（水）（の夜）まで
- 提出方法：LMS(ScombZ)の本授業ページにて提出

【重要】レポートに関する注意

- 他人が作成した文章や実験データを含むレポートを提出した場合，不正行為となります
  - 例外：参考文献の引用（出典と引用範囲を明示していて，引用が適度な分量かつ必要性のある場合に限る）
- 提出レポートの内容に不正行為が見つかった場合，学則に従い処分の対象となります
- レポート作成にあたり下記のことは自分自身でやる
  1. プログラムの作成，実行，結果の分析　などの作業
  2. レポートの文章や図表の作成