自然言語処理

Natural Language Processing

授業URL: https://shibaura-it.zoom.us/j/96136065393

第３回　2026/10/15

芝浦工業大学 工学部
杉本　徹
sugimoto@shibaura-it.ac.jp

前回出題したレポート課題について（コーパスを使ってみよう）

- ScombZ LMSへの提出期限を延長しました

  延長後の提出期限　10/18（日）23:59 まで

（理由：国語研のツールNLBが連休中に使えない日があったため）

※今日の授業では新たな課題（課題2）を出題しますので，混同しないようご注意ください

今日の内容

- 自然言語処理における統計的手法
- 機械学習
  - 機械学習とは
  - 分類器とその使いかた
  - Naive Bayes分類器
  - Support Vector Machine

- 第2回課題: 人名分類の実験 （10/28まで）

その他の参考書

- 機械学習
  - 多数あり．．．

- 自然言語処理＆機械学習
  1. 深層学習以外の機械学習
     - 「言語処理のための機械学習入門」高村大也，2010
  2. 深層学習
     - 「深層学習による自然言語処理」坪井祐太 他，2017
     - 「自然言語処理のための深層学習」Goldberg著，加藤恒昭他訳，2019
     - 「大規模言語モデル入門」山田育矢 他，2023

     他にも Transformer, BERT, PyTorch等に特化した本が多数

自然言語処理における統計的手法

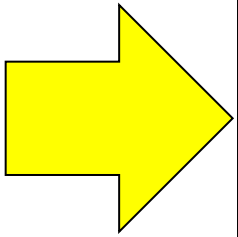
自然言語処理における合理主義と経験主義

合理主義

人間が行う言語処理を分析して理論を作り，それに基づいて人手で処理ルールを書く.

しかし，人手でルールを書くには言語はあまりにも複雑で，例外を大量に含む.

90年代以降



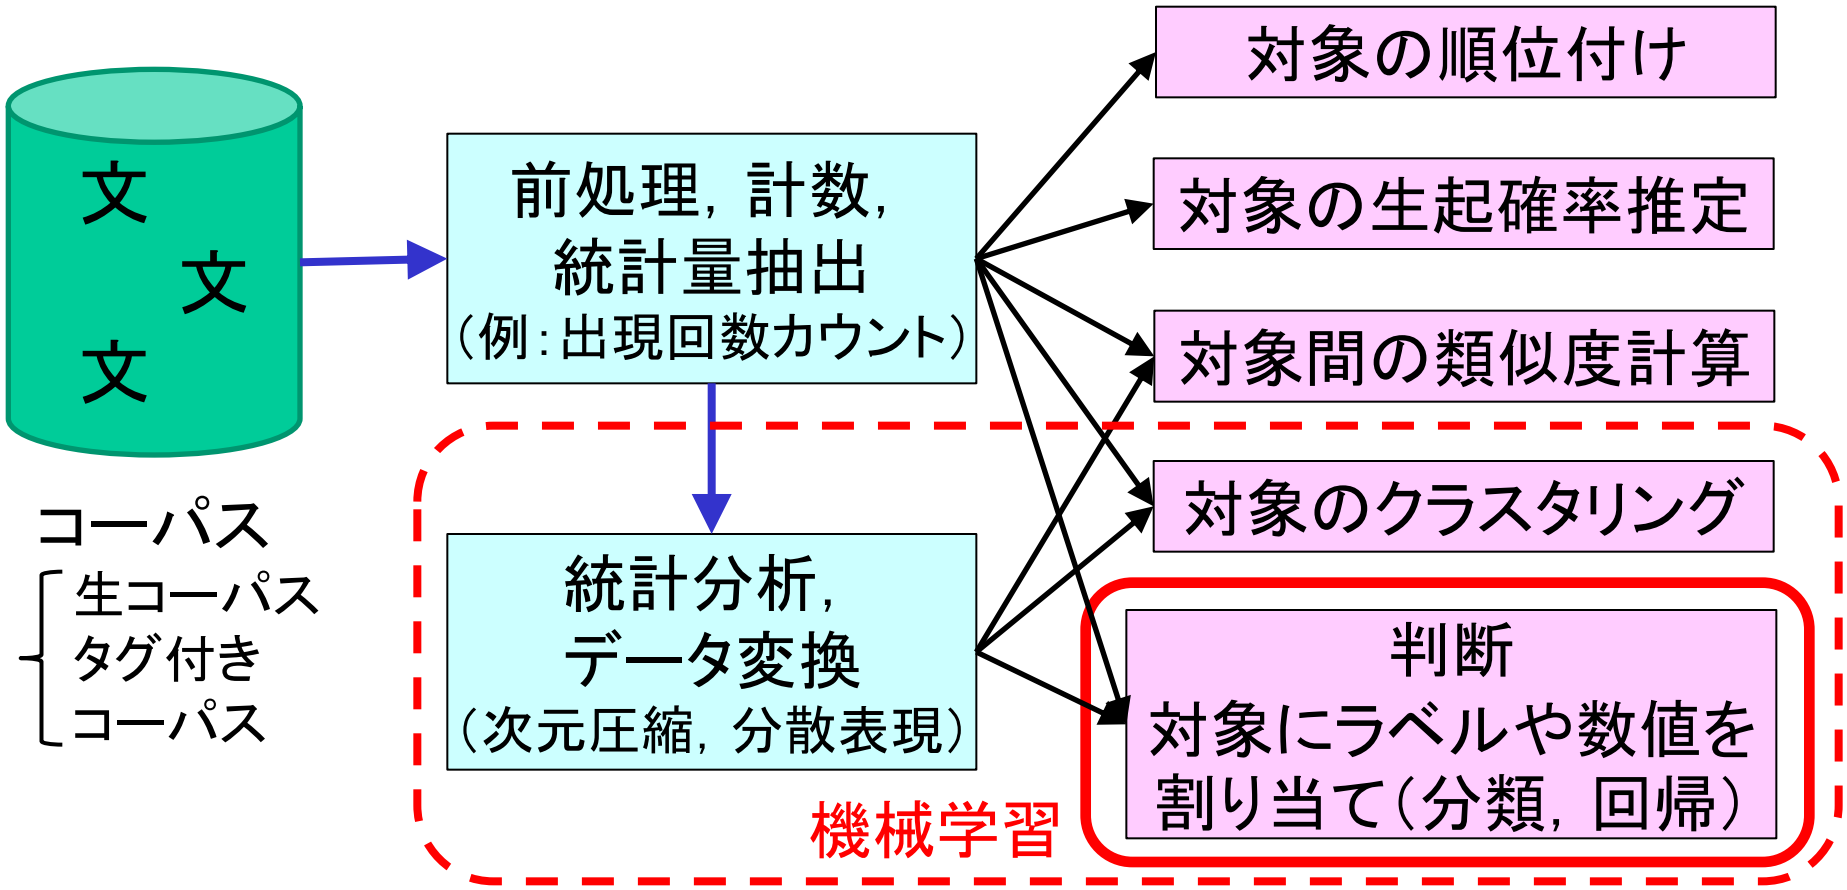
経験主義

言語データの実例（コーパス）を大量に収集し，そのデータ内で観測される事象を中心に考える.

コンピュータ処理により統計的分析や機械学習を行い，解析モデルを作る.

統計的自然言語処理

対象 ＝ 単語，
文，文章など



参考書籍：“Foundations of Statistical Natural Language Processing”, Manning & Schuetze, MIT Press, 1999.（邦訳あり）

機械学習とは

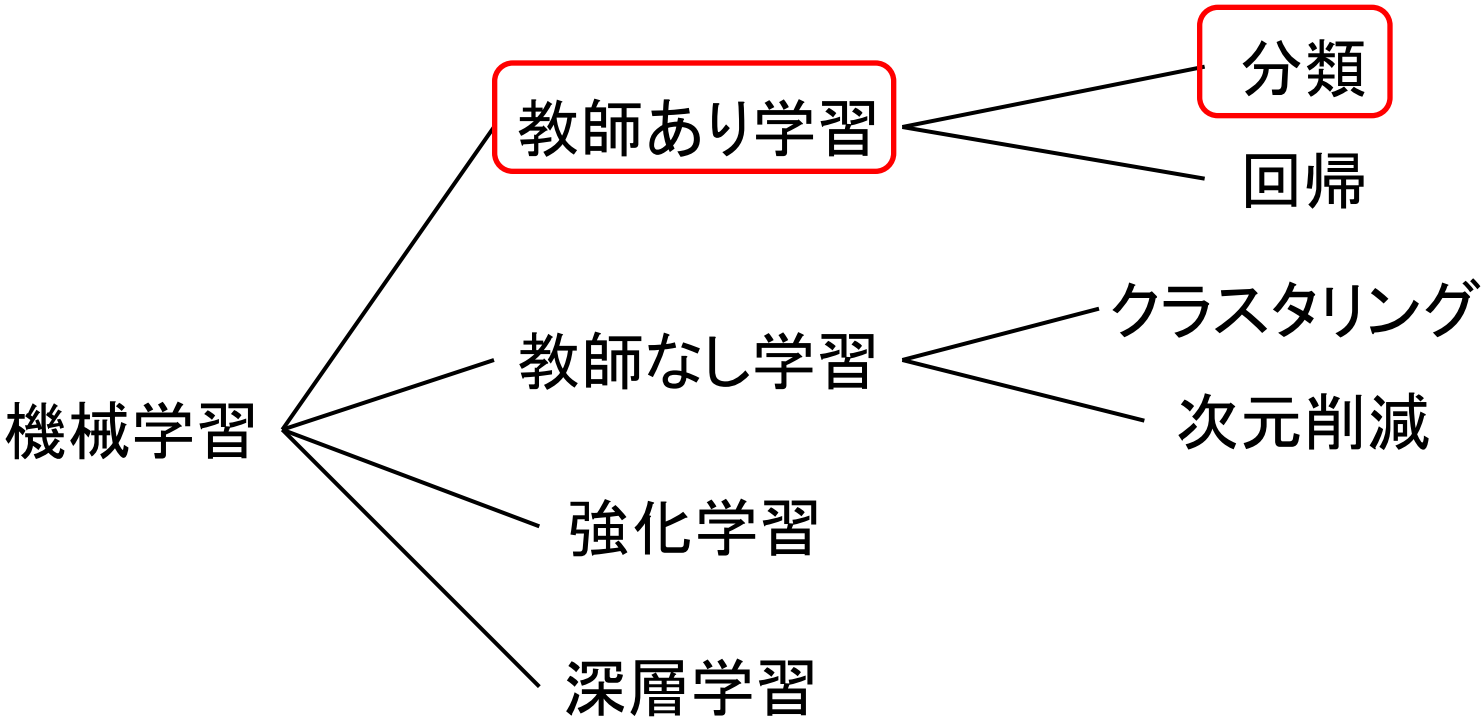
機械学習（machine learning）

- コンピュータが目的に応じた学習を行って，規則や知識を獲得する仕組みを与える
- 大量のデータを機械学習のアルゴリズムを用いて分析することで，役に立つ規則や知識が得られる

- 応用例

1. 大量の画像データを分析することで，画像に写った物体や人物の表情を認識する規則を獲得
2. 購買履歴やSNSの評判情報から今後の売り上げを予測するための知識を獲得

機械学習の分類



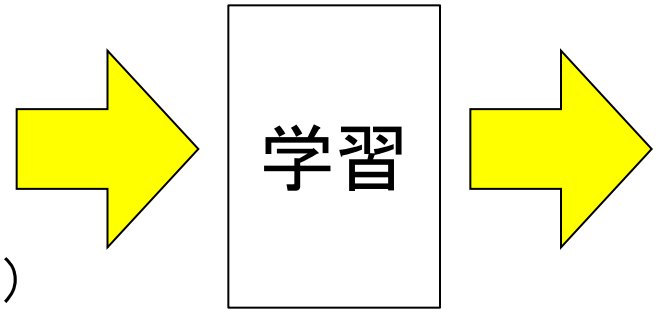
「深層学習」は，深層ニューラルネットワークを用いた学習全般を表すため，他の学習の分類とは観点が異なる

教師あり学習（supervised learning）

- あらかじめ正しい出力データを付与した学習データを人手で用意する手間があるが，多様な問題に適用可能であるため，広く用いられている

学習データ（入力と出力の対）

（入力データ1，正しい出力1）
（入力データ2，正しい出力2）
．．．
（入力データM，正しい出力M）



任意の入力データに対し出力を求める規則

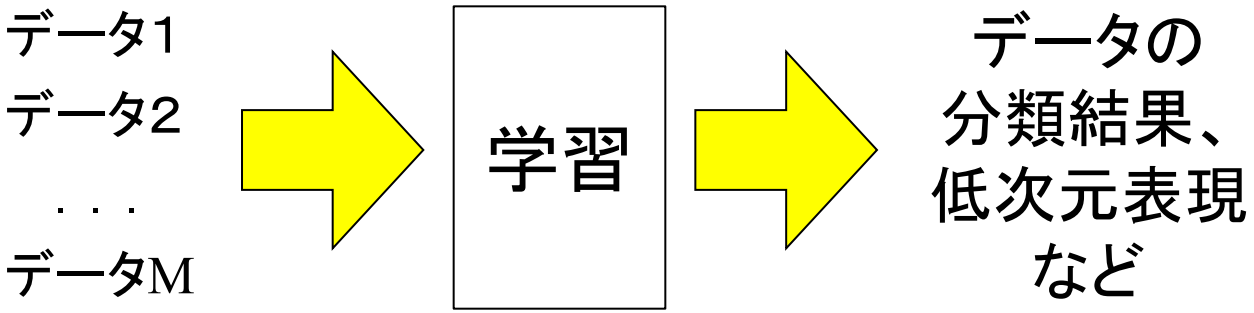
教師あり学習タスクの種類

タスクの種類	出力の内容	代表的なアルゴリズム
分類	ラベル	Naive Bayes, SVM, ニューラルネット
回帰	数値	線形回帰, Support Vector回帰
系列ラベリング	ラベルの列	隠れマルコフモデル(HMM), CRF

- 分類・・・事前に設定した有限個の種類のラベルを各入力データに割り当てるタスク．自然言語処理は言語という記号体系を対象とするため，分類タスクが多く用いられる
- しばしば系列ラベリングも用いられる
  - 形態素解析：文中の単語列に品詞を割り当てる

教師なし学習（unsupervised learning）

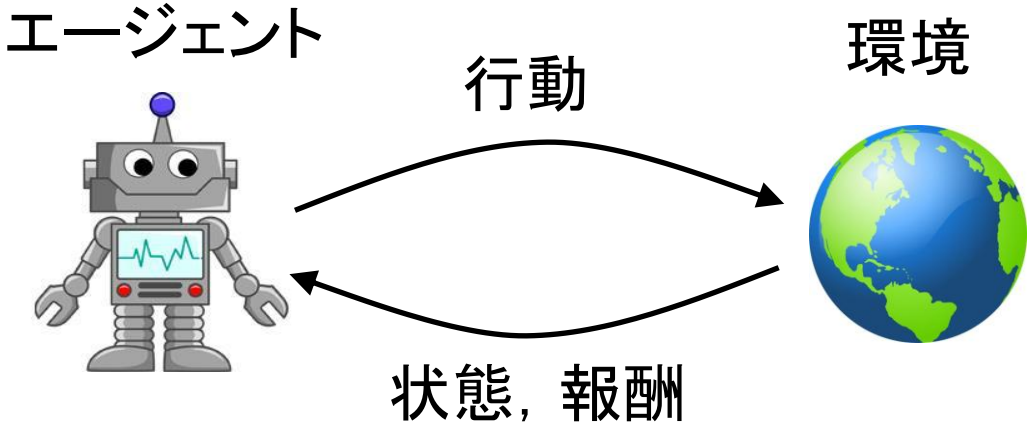
- 出力データを人手で付与するようなことはせず，
  入力データ自体の統計処理により規則や知識を得る



タスクの種類	代表的なアルゴリズム
クラスタリング	階層的クラスタリング，k-平均法
次元削減	主成分分析，トピックモデル，ニューラルネット

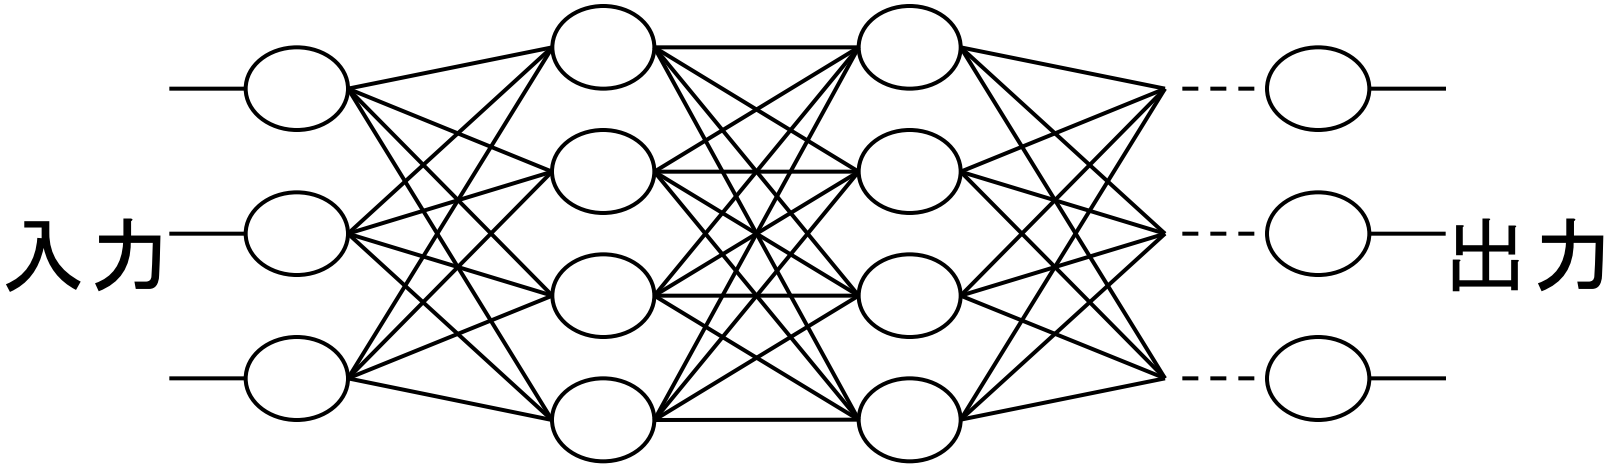
強化学習（reinforcement learning）

- システムが実行した行動の良し悪しを反映したフィードバック（報酬）に基づき，行動戦略を学習する
- 自然言語対話システムで利用事例あり
  - 対話の結果の良し悪しに基づき，応答戦略を改善する
- 深層学習と組み合わせることもできる



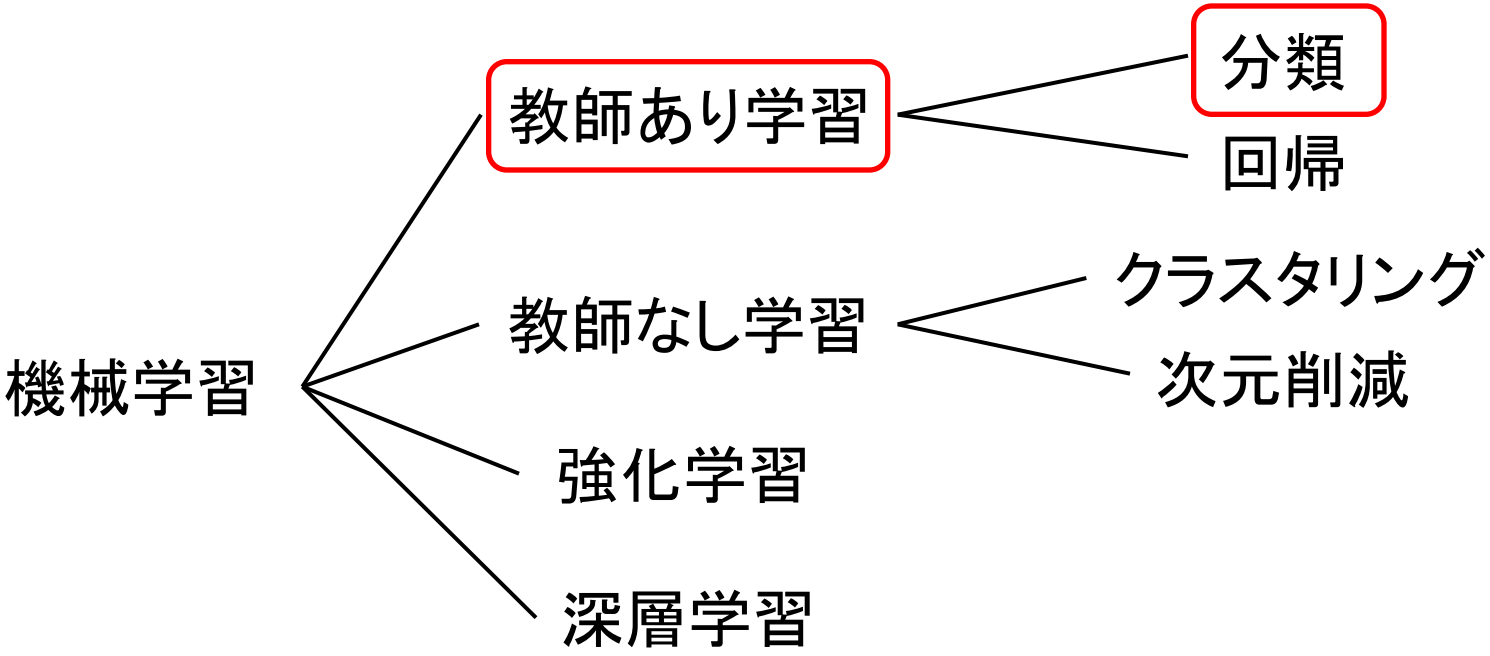
深層学習（deep learning）

- 多層のニューラルネットワークを用いる学習
  - 目的に応じて多様な構造のネットワークが使われる
  - 第11～13回の授業で詳しく説明する



この後の説明内容

- 自然言語処理の広範な問題に適用できる，教師あり学習，とくに分類タスクを扱う
- ここでは深層学習は扱わない



分類器とその使いかた

分類器（classifier）

- 入力データを（あらかじめ決めておいた）複数のカテゴリの中のどれかに分類する

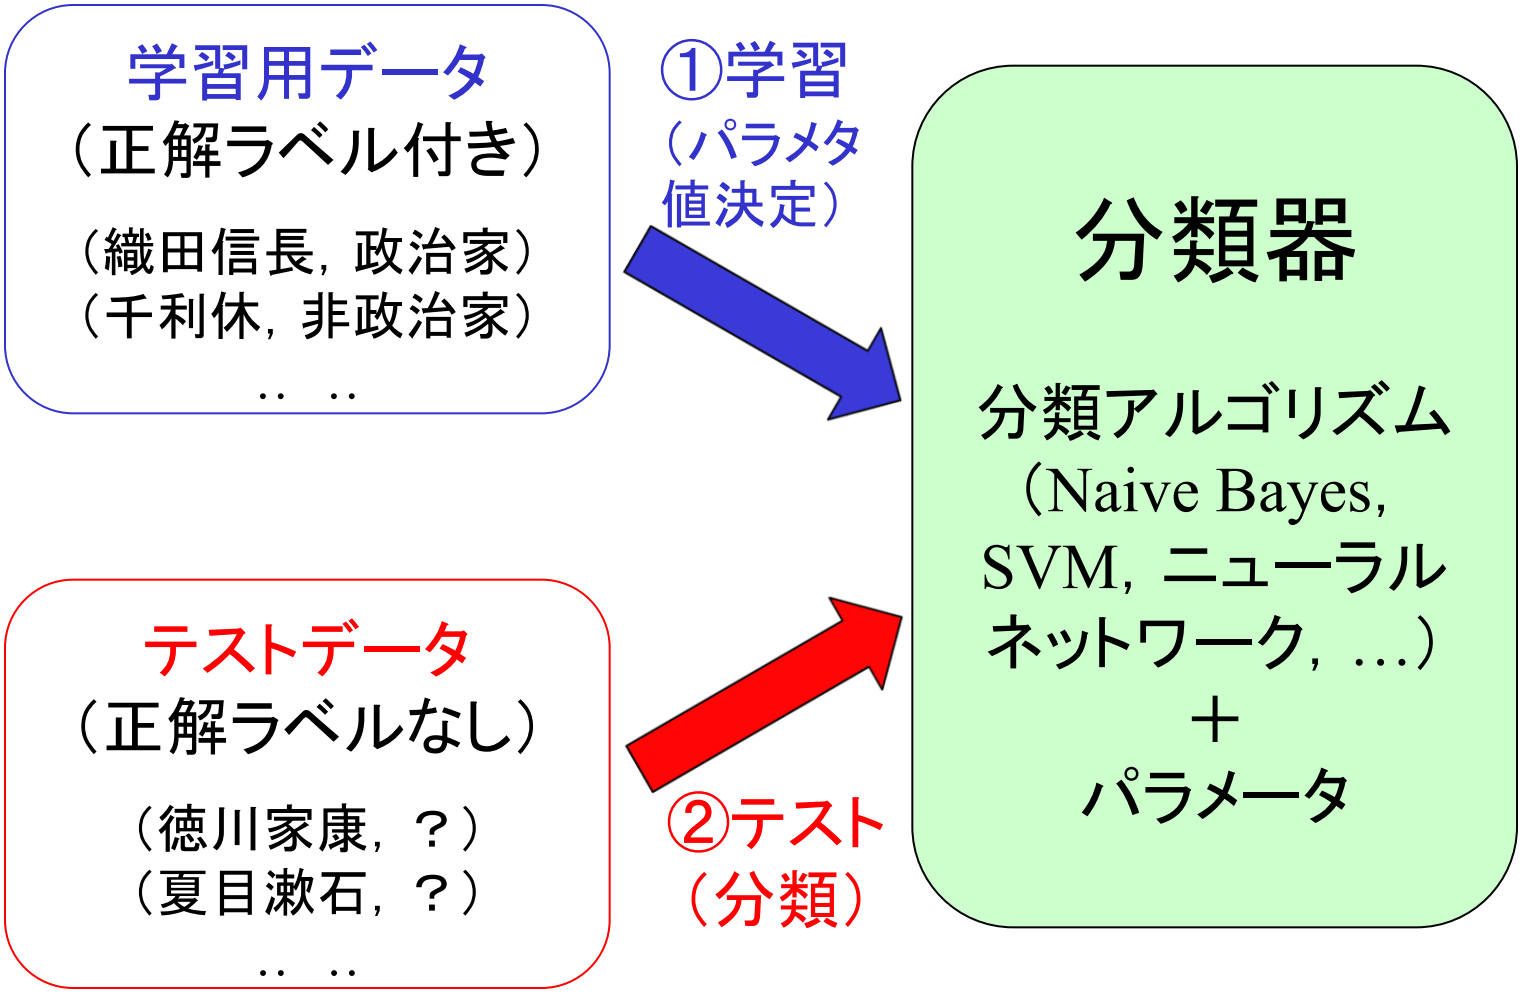
$$c = f(\mathbf{x})$$

x: 入力データ　c: 出力（カテゴリ）

- 例: 入力された人名を政治家と非政治家に分類する

入力データ		出力
織田信長	⟶	政治家
千利休	⟶	非政治家
徳川家康	⟶	政治家
..		..

分類器の学習とテスト


学習用データ
（正解ラベル付き）
（織田信長，政治家）
（千利休，非政治家）
．．　．．
①学習
（パラメタ
値決定）
分類器
分類アルゴリズム
（Naive Bayes,
SVM，ニューラル
ネットワーク，…）
＋
パラメータ
テストデータ
（正解ラベルなし）
（徳川家康，？）
（夏目漱石，？）
．．　．．
②テスト
（分類）

分類器（続き）

$$\boxed{c = f(\mathbf{x})}$$ **x**: 入力データ　c: 出力（カテゴリ）

- 入力データ **x** は通常，実数値（または整数値）ベクトル．入力に含まれる様々な側面の値を並べたもの

  → 特徴ベクトル．その要素は特徴（素性（そせい），feature）

- 出力カテゴリが 2種類に限定される場合，2値分類（よくあるのは yes/no 判定），3種類以上ある場合 多値分類という
  - 多値分類問題は，複数の 2値分類問題の組み合わせに変換できる（one-vs-rest法，pairwise法など）

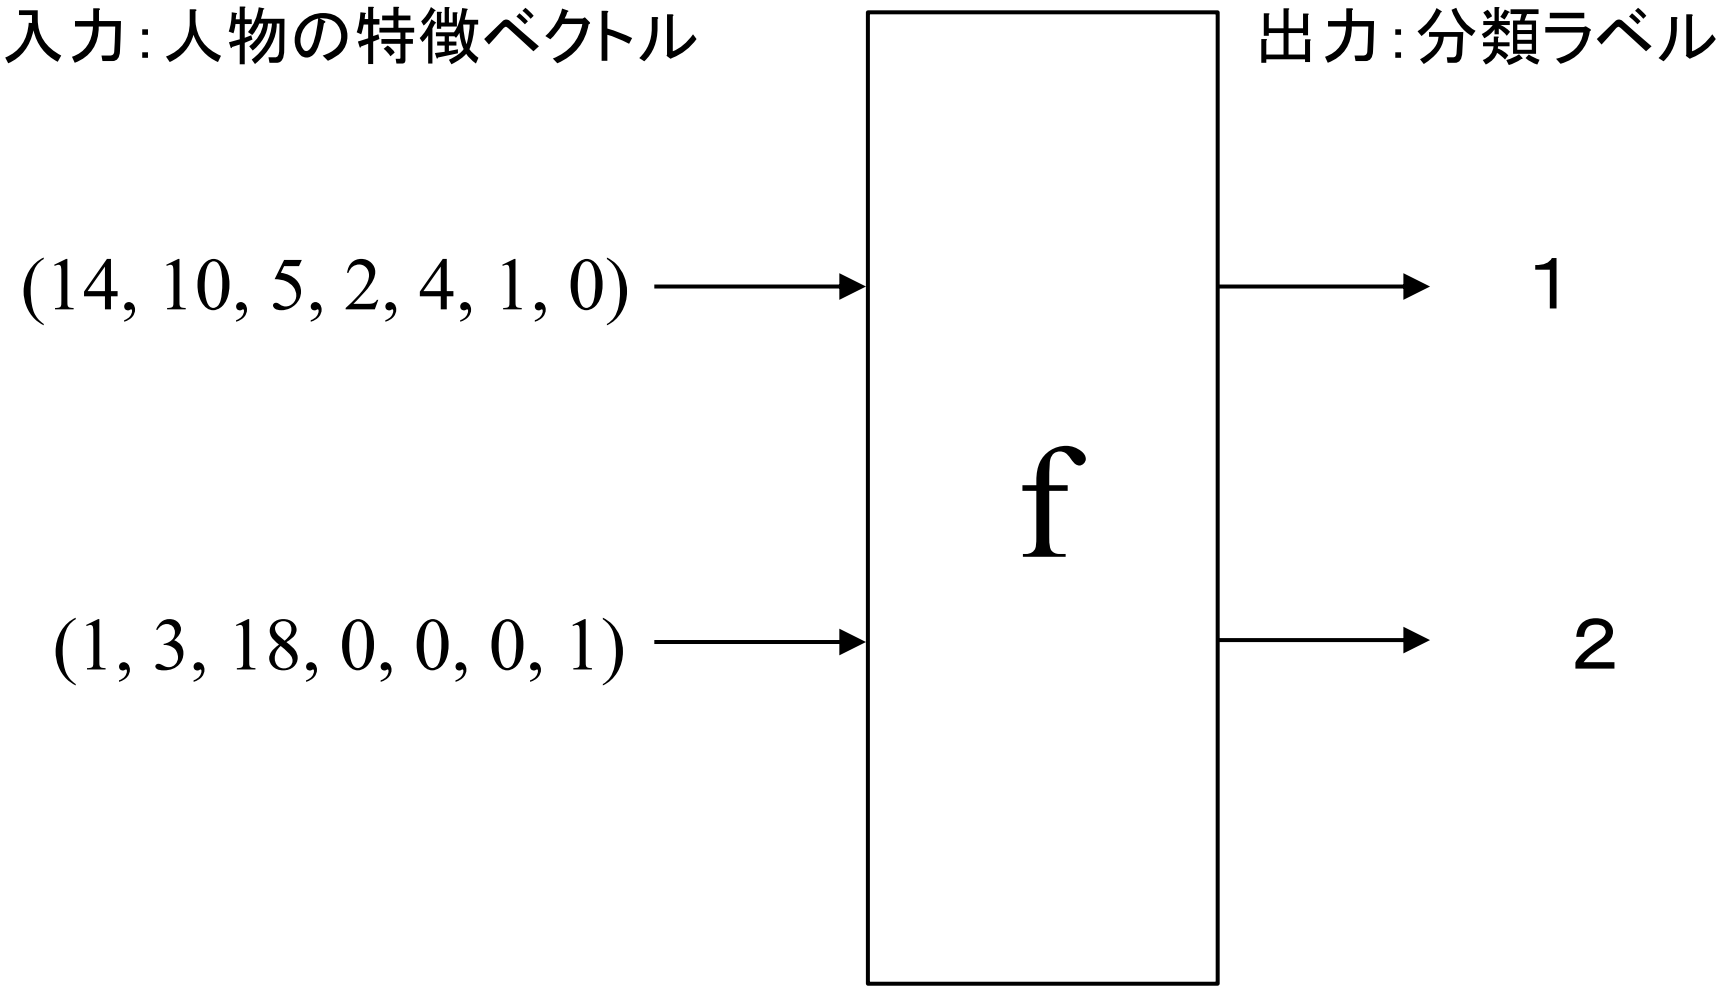
例題: 人名の分類

- 特徴量: 対象の人物について書かれた Web ページに含まれるいくつかの単語の出現回数

	「城」	「大名」	「茶」	「明治」	「大臣」	「戦争」	「作品」
織田信長	14	10	5	2	4	1	0
千利休	1	3	18	0	0	0	1
徳川家康	12	12	3	1	5	1	0
…	…	…	…	…	…	…	…

例: 織田信長の特徴ベクトルは (14, 10, 5, 2, 4, 1, 0)

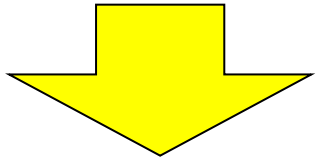
- 出力カテゴリ: 政治家(1) or 非政治家(2)


入力：人物の特徴ベクトル
出力：分類ラベル
(14, 10, 5, 2, 4, 1, 0)
(1, 3, 18, 0, 0, 0, 1)
f
1
2

分類器の使用手順

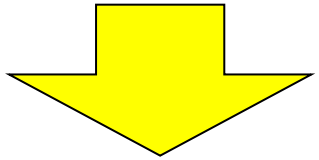
① データの用意

前処理，特徴抽出，特徴選択



② 学習

ハイパーパラメータの調整



③ 適用，評価

① データの用意

- 学習データ（特徴ベクトルと正解ラベルの対）の作成
- 必要なデータ数（100? 1000? 1万?）は問題に依存
- 特徴ベクトルの作成方法
  1. 前処理：自然言語の場合は，文字の正規化，文分割，形態素解析，不要語除去など
  2. 特徴抽出
  3. スケーリング（値の範囲の正規化）
  4. 特徴選択：特徴ベクトルの次元を減らすために，分類に役立たないと思われる特徴は事前に除去する

分類に役立つかの判断・・・ 相互情報量，カイ二乗値

② 学習

- 用意した学習データ（訓練データ，training data）を用いて，分類器固有のアルゴリズムにより学習を行う

- ハイパーパラメータの調整
  - ハイパーパラメータ：事前に値を設定し，学習の過程では固定した値として使用するパラメータのこと
    （SVMのコスト C，ニューラルネットの中間ユニット数など）
  - 訓練データとは異なるデータ（開発データ）を用いて，複数の値を試し，ハイパーパラメータの最適な値を求める（グリッドサーチなど）

③ 適用，評価

- 学習が終った後の分類器に対して，新たなデータ（正解ラベルなし）を入力し，そのデータに対応すると推測されるラベルを出力する

- 学習済みの分類器の分類精度評価
  - 選んだ分類器の種類が適切か
  - 用意した学習データが十分か

  を判断するための実験

分類器の評価方法

- テストデータ
  - 学習済みの分類器の性能評価に使用するデータ
  - 学習に使った訓練データとは異なるデータを使う
  - 学習データと同じく，特徴ベクトルと正解ラベルの対の形をしていて，このうち特徴ベクトルを分類器に与えて得られた出力と，正解ラベルを比較する（→ 次スライド）
- k分割交差確認法（k-fold cross validation）
  - 使用可能な全データを事前に k 等分する．この中の k-1 個を使って学習を行い残りの1つを使ってテストを行う，という処理を k 回繰り返し，最後に得られた評価結果の平均を求める

分類器の出力と正解ラベルの比較

- 混同行列（confusion matrix） 対角線が正しい推測

		正解ラベル			
		ラベル 1	ラベル 2	・・・	ラベルm
分類器の推測（出力）	ラベル 1	■			
	ラベル 2		■		
	・・・			■	
	ラベルm				■

- 正解率（accuracy）$=\frac{\text{推測が正しかったテストデータ数}}{\text{全テストデータ数}}$
- この他に，ラベル種類ごとの適合率（precision），再現率（recall），F値（F-measure）といった尺度もある

Naive Bayes分類器

Naive Bayes分類器とは

- 確率に基づく分類アルゴリズム
- Bayes の定理を使って，事後確率を求める
- 入力データの各特徴（素性）が互いに独立であるという単純（naive）な仮定をおく
- 単純なモデルの割に，分類精度はまずまず
- 応用例：迷惑メールの判定

- 事後確率 $P(c \mid \mathbf{x})$ を最大化する c を求める
- Bayes の定理より

$$P(c \mid \mathbf{x}) = \frac{P(\mathbf{x} \mid c) \times P(c)}{P(\mathbf{x})}$$

  - 分母は c の選び方に依存しないので無視できる

- 特徴ベクトル $\mathbf{x} = (x_1, x_2, \ldots, x_n)$ の各成分 x_i の出現が互いに独立であると仮定すると,

$$P(\mathbf{x} \mid c) = \prod_{i=1}^{n} P(x_i \mid c)$$

したがって,

$$f(\mathbf{x}) = \underset{c}{\operatorname{argmax}} \left(P(c) \times \prod_{i=1}^{n} P(x_i \mid c)\right)$$

パラメータの推定

- $P(x_i \mid c)$ の値の推定方法は，特徴 x_iの確率分布によって変わる
- ここでは簡単のため，x_iは 0, 1 の2種類の値のみをとると考えて，条件 c の下で，一定の確率 $p(x_i, c)$ で x_i は 値 1 を，確率 $1-p(x_i, c)$ で値 0 をとると仮定する（ベルヌーイ分布）

- 学習データを用いた最尤推定

$$P(c) = \frac{\text{正解データが c の学習データの数}}{\text{全学習データ数}}$$

$$P(x_i \mid c) = \text{if } (x_i = 1) \text{ then } p(x_i, c) \text{ else } 1 - p(x_i, c)$$

$$\text{ただし，} p(x_i, c) = \frac{\text{正解ラベルが c で } x_i = 1 \text{である学習データ数}}{\text{正解ラベルが c の学習データの数}}$$

ゼロ頻度問題と Smoothing

- ゼロ頻度問題，sparseness の問題
  - データが少ない特徴値に対しては，信頼性の高い推定が行えない．その特徴値をもつデータが 0 個の場合，特徴値の推定確率が 0 となり，全体の確率値も 0 になる

- Smoothing（Discounting，MAP推定）
  - データが多い特徴値に対する推定値を値引きする代わりに，データが少ない特徴値に対する推定値を増やす
  - 例：

3/4（.75）	加算smoothing	4/7（.57）
1/4（.25）	⟶	2/7（.29）
0/4（.00）		1/7（.14）

Naive Bayes分類器の使用手順

1. 学習フェーズ

与えられた学習データから確率 $P(c)$ および $p(x_i, c)$ の推定値を各 c および x_i の組み合わせに対して計算し，保存する

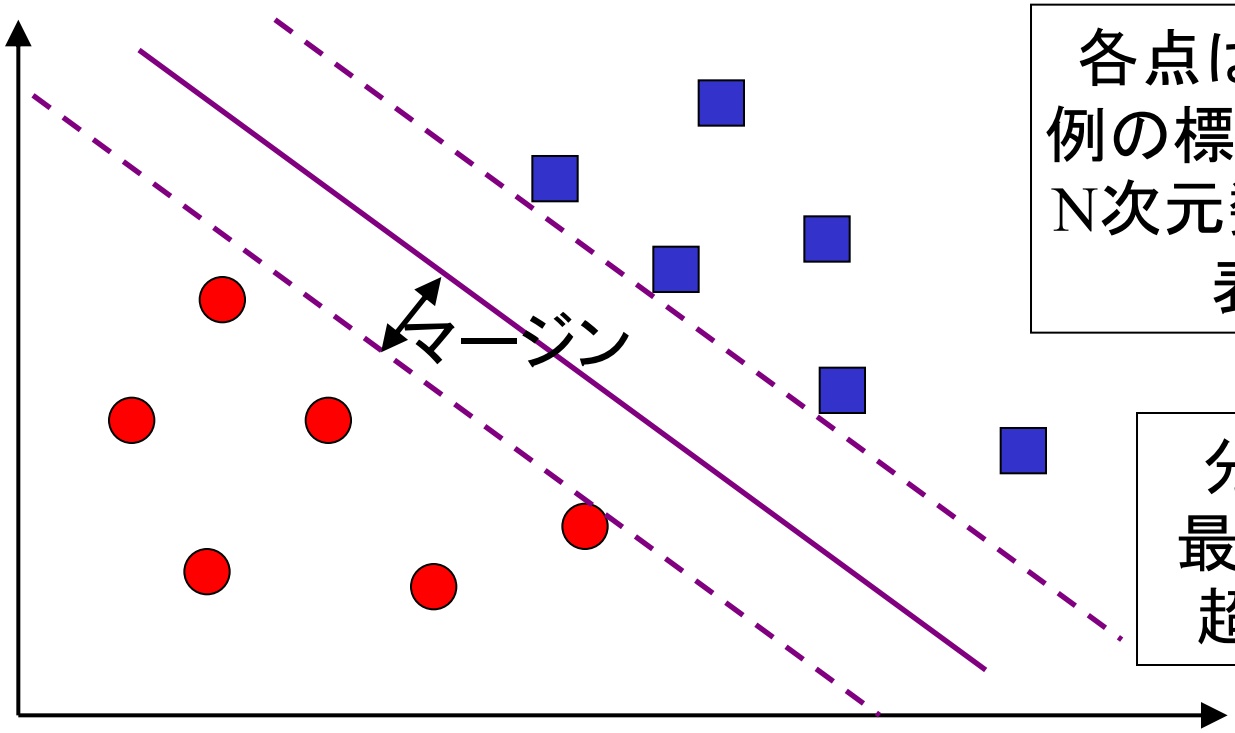
2. 適用フェーズ

与えられた入力データ $\mathbf{x}$ から各ラベル c に対して $P(c)\,P(\mathbf{x} \mid c)$ の値を計算し，値が最大となるラベル c を分類結果として出力する

Support Vector Machine

Support Vector Machine (SVM)

- （2値）分類問題を解く学習アルゴリズムの一種



各点は正例または負例の標本データを表し，N次元数ベクトルとして表現される

分離マージンを最大化するような超平面を求める

SVM は線形分類器の一種

- 線形分類器

  入力データ $x = (x_1, x_2, ..., x_n)$ に対して

  $$f(x) = w_1x_1 + w_2x_2 + ... + w_nx_n - b = \Sigma\, w_ix_i - b$$

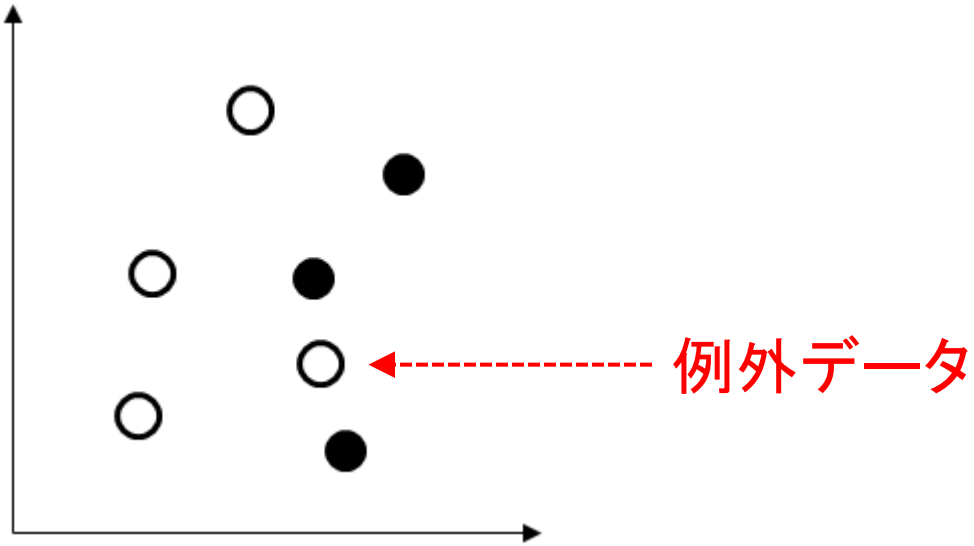
  の値を計算し，$f(x) \geqq 0$ ならば正クラス，$f(x) < 0$ ならば負クラスに分類する

- SVM では，マージンの縁にある少数のデータ（サポートベクトル）から各 w_i の値を求めることができる

制約を緩和したSVM

- 超平面による分離の際に，多少の例外データを認める

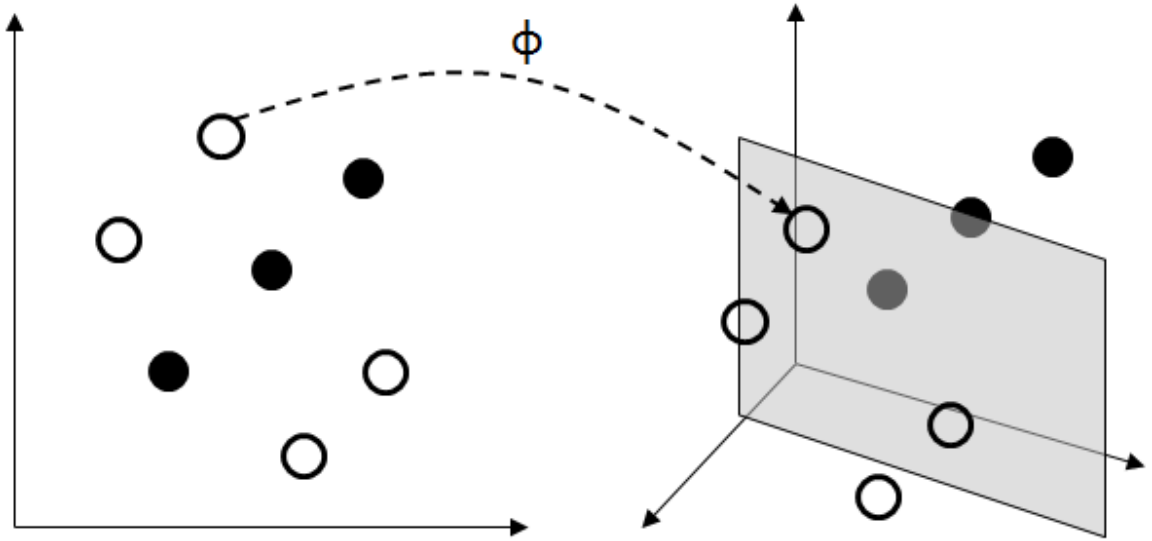
例：



- 例外データに対するペナルティの係数（コスト）Cを調整可能（ハイパーパラメータ）

Kernel method

- 超平面で分離（線形分離）できない場合でも，Kernel 関数（多項式カーネル，RBFカーネルなど）によりデータを高次元に射影することで，線形分離できる場合がある（実質的には非線形分離に相当）
- 高次の Kernel を使うことで，特徴の組み合わせ（共起関係）を考慮できるようになる



a) 平面による分離は困難　　b) 高次元に写像して分離

Support Vector Machineの使用手順

1. 学習フェーズ

与えられた学習データを用いて最適化問題を解いて，サポートベクトルの集合とそれらの重みを求めて保存する

2. 適用フェーズ

与えられた入力データ $\mathbf{x}$ に対して線形分類器の $f(x)$ を求める式の値を計算し，$f(x) \geqq 0$ ならば正クラス，$f(x) < 0$ ならば負クラスに分類する

LIBSVM ライブラリ

- 国立台湾大学で開発されたフリーのSVMライブラリ
- LIBSVM の主なハイパーパラメータ
  - C : 制約を緩和したSVMにおけるペナルティの係数
  - kernel_type : カーネルの種類
    （LINEAR：線形分類，POLY：多項式カーネル，RBF：RBFカーネル）
  - gamma : POLY, RBF で有効なパラメータ
  - degree : POLY における多項式の次数
  - coef0 : POLY における係数
- Java から呼び出して使う場合，libsvm.jar が必要
- Python では sklearn.svmモジュールとして利用可能

第2回課題
人名分類の実験

（再掲）例題: 人名の分類

- 特徴量: 対象の人物について書かれた Web ページに含まれるいくつかの単語の出現回数

	「城」	「大名」	「茶」	「明治」	「大臣」	「戦争」	「作品」
織田信長	14	10	5	2	4	1	0
千利休	1	3	18	0	0	0	1
徳川家康	12	12	3	1	5	1	0
…	…	…	…	…	…	…	…

例: 織田信長の特徴ベクトルは (14, 10, 5, 2, 4, 1, 0)

- 出力カテゴリ: 政治家（1） or 非政治家（2）

配布する学習データのファイル形式

正解ラベル　　特徴ベクトル（の疎ベクトル表現）

```
<label>  <name>  <index1>:<value1>  <index2>:<value2> ・・・
<label>  <name>  <index1>:<value1>  <index2>:<value2> ・・・
<label>  <name>  <index1>:<value1>  <index2>:<value2> ・・・
  ・・・
```

- label : 正解ラベル（1以上の整数）
- name : データ名（デバッグ時の識別用）
- index : 何番目の特徴かを表す（1以上の整数）
- value : その特徴の値（一般には実数）

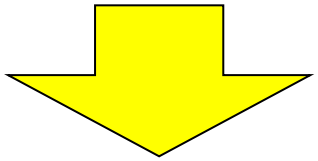
疎ベクトル表現: value が 0 の箇所は省略可

人名データ（person_data.txt）

1　武田信玄　1:6　2:5
2　千利休　1:1　2:3　3:18　7:1
1　上杉謙信　1:25　2:3　4:1
…

正解ラベル（1列目）は
政治家（1） or 非政治家（2）

全20人分のデータを含む

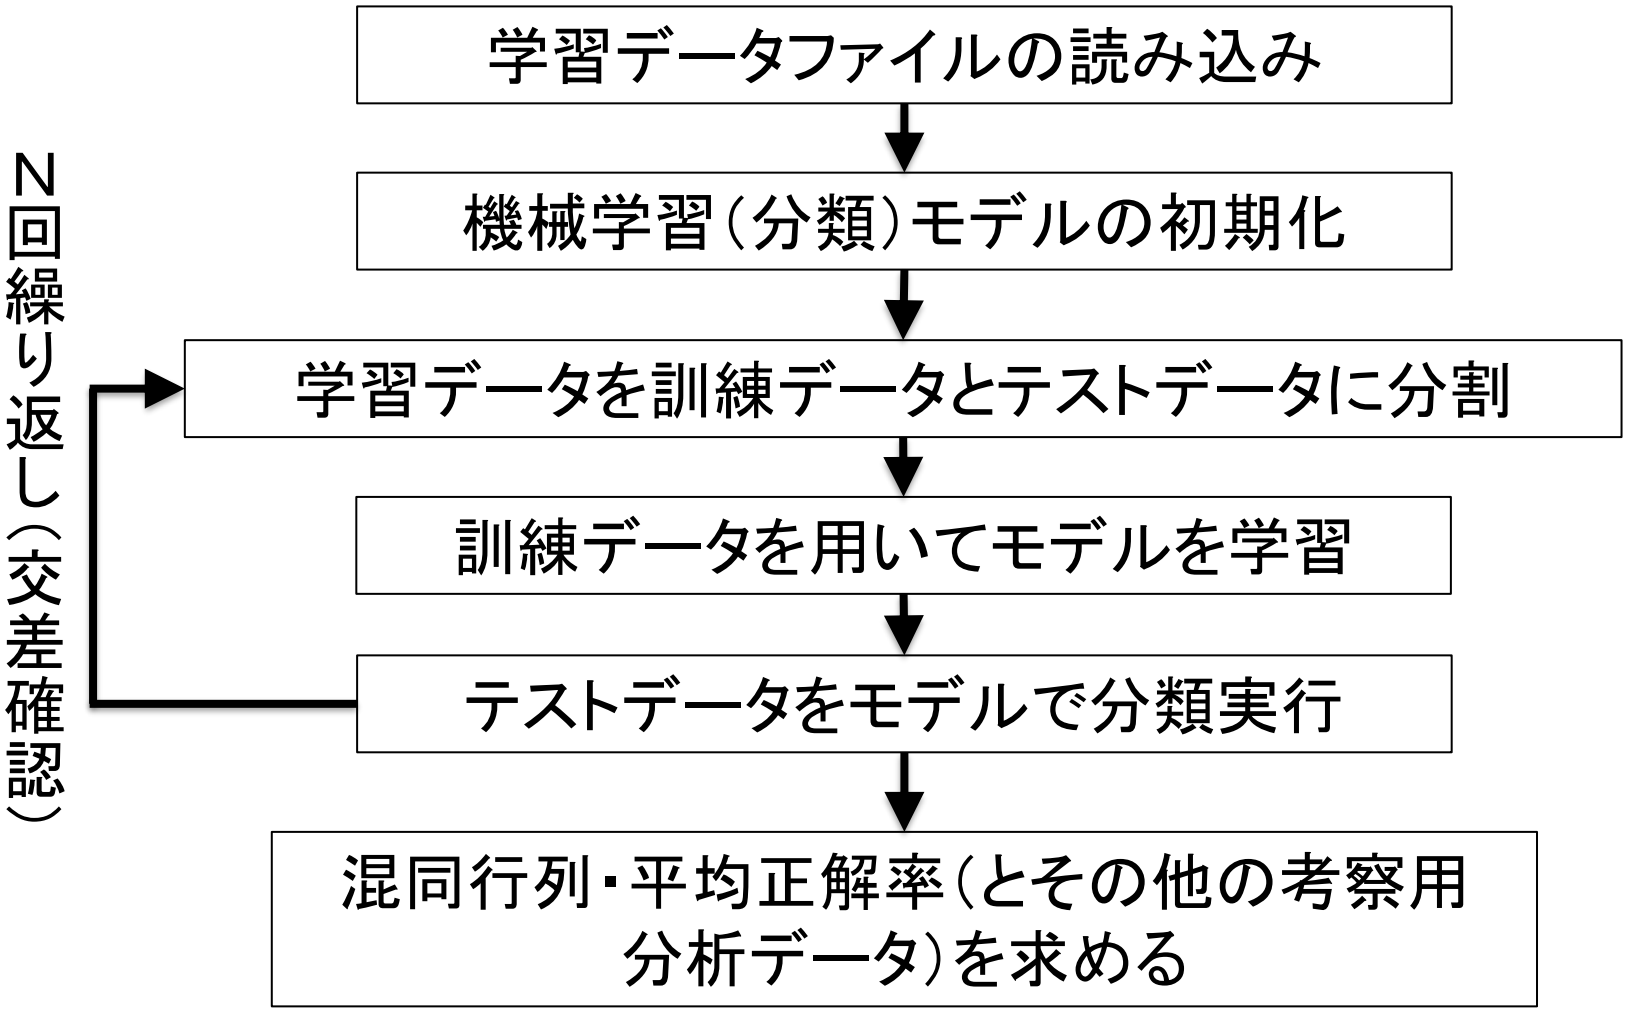


	1.「城」	2.「大名」	3.「茶」	4.「明治」	5.「大臣」	6.「戦争」	7.「作品」
武田信玄	6	5	0	0	0	0	0
千利休	1	3	18	0	0	0	1
上杉謙信	25	3	0	1	0	0	0
…	…	…	…	…	…	…	…

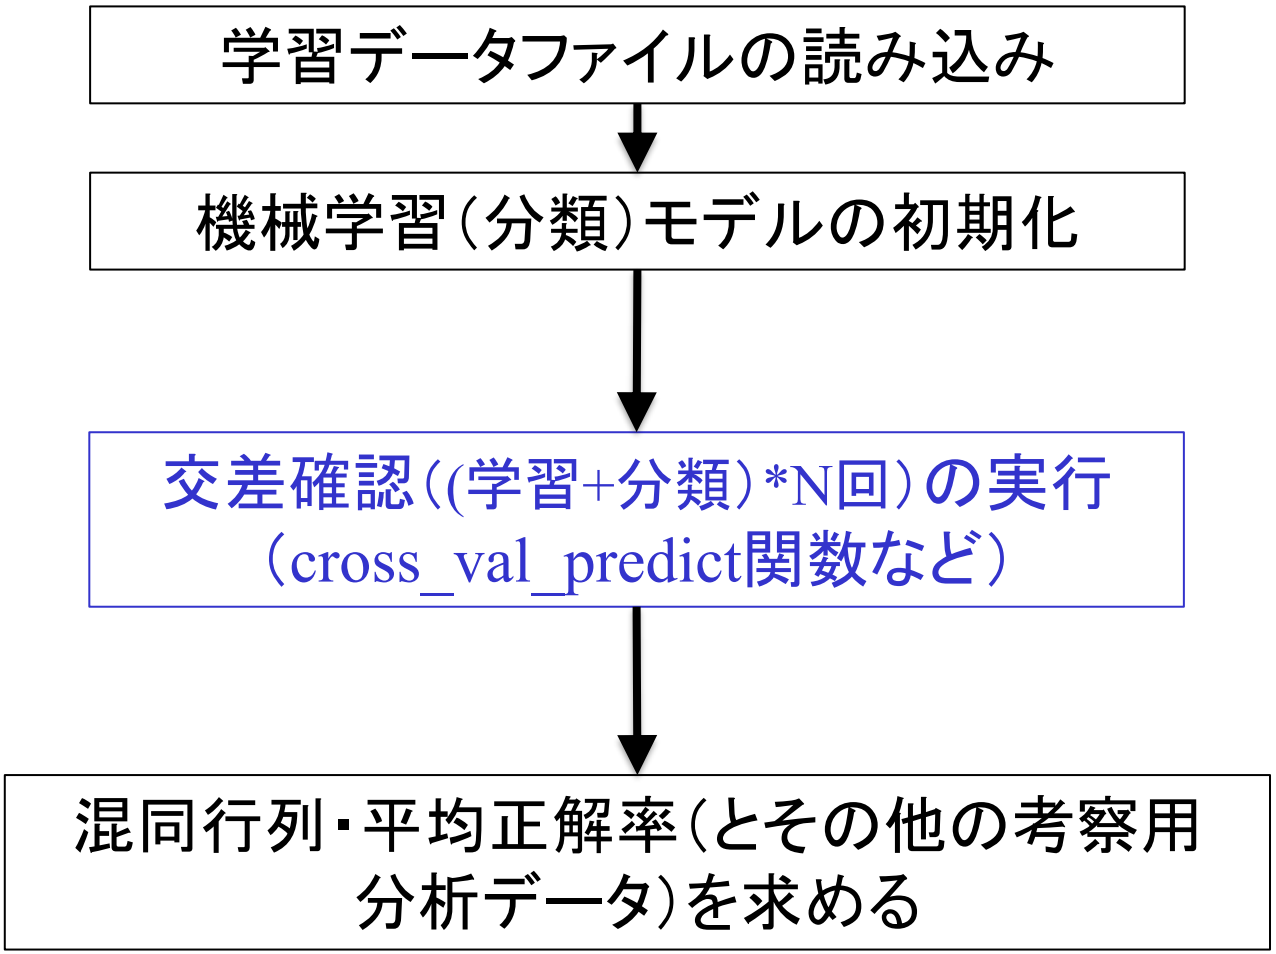
課題1：人名分類の実行

- person_data.txt を用いて人名分類を複数の方法で実行しなさい
  - 各方法において，10分割交差確認により，混同行列と平均正解率を求めること
  - person_data.txt には学習データが20個あるので，その中の2個をテストデータとし，残りの18個を訓練データとして学習とテストを行う，ということを10回繰り返す
  - 「複数の方法」の意味（例）
    ① 複数種類の分類モデルで実行（例：Naive Bayes と SVM）
    ② 1つの分類モデルの複数のハイパーパラメータ値で実行

ヒント: プログラムの処理手順



Python の cross_val系の関数を使う場合



ヒント: 学習データファイル読み込みのプログラム例

```
# 疎ベクトルのテキスト表現からベクトルへの変換
def create_vec(str, min, max):
  vect = [0] * (max - min + 1)
  for s in str.split(" "):
    pos, val = s.split(":")
    vect[int(pos) - min] = int(val)
  return vect

# 学習データファイル読み込み
labels = []  # 学習データ中の正解ラベルのリスト
names = []   # 学習データ中のデータ名のリスト
vectors = [] # 学習データ中の特徴ベクトルのリスト
with open("person_data.txt", encoding="utf-8") as tf:
  for line in tf:
    split = line.strip().split("¥t")
    labels.append(split[0])
    names.append(split[1])
    vectors.append(create_vec(split[2], 1, 7))
```

ヒント: 機械学習モデルの初期化

- Pythonの sckit-learnライブラリ（sklearn）に Naive Bayesや SVM など様々な機械学習モデルが用意されている
  - Naive Bayes　model = BernoulliNB()
  - SVM　　model = SVC(kernel='linear', C=0.5)　値は任意

- 分類モデルは他にも用意されているので試すのもよい

ヒント: 交差確認法による学習と評価

- 次の式により10分割交差確認法を実行し，全学習データに対する分類結果をリスト形式で得ることができる

  preds = cross_val_predict(model, vectorlist, labellist, cv=10)

  この分類結果のリストをファイルから読み込んだ正解ラベルリストと比較すれば，正解率や混同行列を求めることができる

  （他の方法として，正解率を求めるのに cross_val_score，混同行列を求めるのに confusion_matrix を使う手もある）

参考: 交差確認法ではなく，訓練データとテストデータを指定して実行する場合は，model.fit(訓練データのベクトルリスト，訓練データのラベルリスト）で学習し，model.predict（テストデータのベクトル）で分類結果を得る

課題２：エラー分析

- 課題１で行った実験（のうちの１回分だけでもよい）のエラー分析を行いなさい
  - 正しく分類されなかったデータは何と何であったか調べて，それらに共通する特徴がないか，誤分類された原因として何が考えられるか，などを考察しなさい

課題３：特徴分析

- person_data.txt で使われる7つの特徴（「城」，…，「作品」）のうち，①政治家カテゴリに偏って現れるもの，②非政治家カテゴリに偏って現れるもの，③両方のカテゴリに偏らず現れるもの，を調べなさい
  - ある特徴が「偏って現れる」という現象をどのように定式化して分析するかは各自で考えること
  - 次ページに 1つの手法を挙げるが，その方法を使ってもよいし自分で考えた分析方法でもよい

参考：相互情報量

- 2つの確率変数の関連の強さを表す尺度の1つ
  - 分類器が用いる特徴量に対して，正解ラベルとの相互情報量を求めることで，分類におけるその特徴量の有効性を見積もることができる
  - 2つの確率変数 X, Y の相互情報量

$$I(X;Y) = \sum_{y \in Y} \sum_{x \in X} p(x,y) \log \frac{p(x,y)}{p(x)\,p(y)}$$

確率変数 X：特徴 x_i が学習データに出現するかどうか（0 or 1）

確率変数 Y：その学習データの正解ラベル（1 or 2）

相互情報量の計算例

（人名分類において特徴「城」の重要性を見積もる）

- Person_data.txt において
  - 政治家10人中，特徴「城」を持つのは 7人
  - 非政治家10人中，特徴「城」を持つのは 2人

特徴「城」に関する分割表

		特徴「城」を		合計
		持つ	持たない	
正解ラベル	政治家	7	3	10
	非政治家	2	8	10
合計		9	11	20

- 特徴「城」の相互情報量

$$\frac{7}{20}\log\frac{20\cdot 7}{10\cdot 9}+\frac{3}{20}\log\frac{20\cdot 3}{10\cdot 11}+\frac{2}{20}\log\frac{20\cdot 2}{10\cdot 9}+\frac{8}{20}\log\frac{20\cdot 8}{10\cdot 11}=0.191$$

(注) log の底は 2を使用

レポートの形式，期限，提出方法

- 形式：電子ファイル（PDF形式）
- 内容構成：レポートの内容に，下記の①②③を
  （それぞれの課題について）含めること
  - ①調査方法の説明
  - ②調査結果（必要に応じて表やグラフを用いる）
  - ③結果についての考察
- 期限：10月28日（水）（の夜）まで
- 提出方法：LMS(ScombZ)の本授業ページにて提出