自然言語処理

Natural Language Processing

授業URL: https://shibaura-it.zoom.us/j/96136065393

第４回　　2026/10/22

芝浦工業大学 工学部
杉本　徹
sugimoto@shibaura-it.ac.jp

前回出題した課題
（人名分類）に関して

第2回課題　人名分類の実験
（詳細は前回のスライド参照）

- 課題1　人名分類の実行
  - 人名分類を複数の方法（Naive Bayes，SVMなど）で実行し，10分割交差確認により混同行列と正解率を求める
- 課題2　エラー分析
  - 課題1で行った実験のエラー分析を行う
- 課題3　特徴分析
  - 課題1で用いた各特徴のカテゴリによる偏りを調べる

（カテゴリごとの出現回数を数える，相互情報量を求める，など）

- 提出期限　10/28（水）夜までに ScombZに提出

レポートの形式，期限，提出方法

- 形式：電子ファイル（PDF形式）
- 内容構成：レポートの内容に，下記の①②③を
  （それぞれの課題について）含めること
  - ①調査方法の説明
  - ②調査結果（必要に応じて表やグラフを用いる）
  - ③結果についての考察
- 期限：10月28日（水）（の夜）まで
- 提出方法：LMS(ScombZ)の本授業ページにて提出

参考：文書分類（Document Classification）

- 文書をその内容に基づいて，事前に設定された複数のカテゴリのいずれかに分類する技術
  - 例：ニュース記事のカテゴリ分類，レビュー記事のポジネガ（positive/negative）分類，スパムメール判定
- 今回の問題（人名分類）は，各人物について書かれたWebページの文書分類とも見なせる

文書分類については，第９回授業で詳しく説明します．
その際に，短文のポジネガ分類を課題とする予定．

参考：2018/10/11 のReuters記事 Amazon scraps secret AI recruiting tool that showed bias against women

- Amazon社が応募者の履歴書を文書分類技術により★～★★★★★に自動分類するシステムを試作
- 過去10年間の採用者の履歴書を使って機械学習したところ，技術職に関して，性別による差別が行われることが分かった
  - たとえば “women’s” という語を含む履歴書を低く評価する（例：“women’s chess club captain”）
- Amazon社は多様性に配慮するようにシステム改良

今日の内容

- 形態素解析(1)解析手法
  - 形態素解析の概要
  - 単語辞書
  - 形態素解析アルゴリズム(コストを用いない方法)
  - 形態素解析アルゴリズム(コストを用いる方法)

形態素解析の概要

はじめに: 自然言語の解析処理

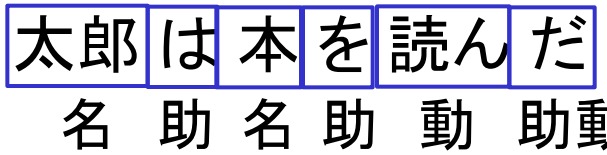
- 与えられた文や文章を自動的に分析して，どんな単語が含まれているか調べたり（形態素解析），それら単語間の構文的関係を求めたり（構文解析），各単語の意味や単語間の意味的関係を明らかにしたり（意味解析）する処理
- システムに入力された文を解析することで，情報を抽出したり発話の意図を推測したりできる
- 参考：逆に表現すべき情報内容や発話意図が与えられて，それを表す自然言語文を作り出す処理を自然言語の生成処理と言う

自然言語の解析処理の流れ

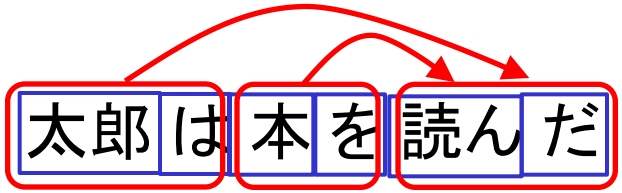
入力文

「太郎は本を読んだ。」

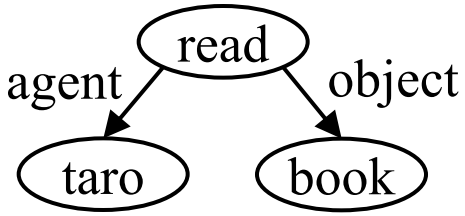
第4,5回 ① 形態素解析



第6回 ② 構文解析



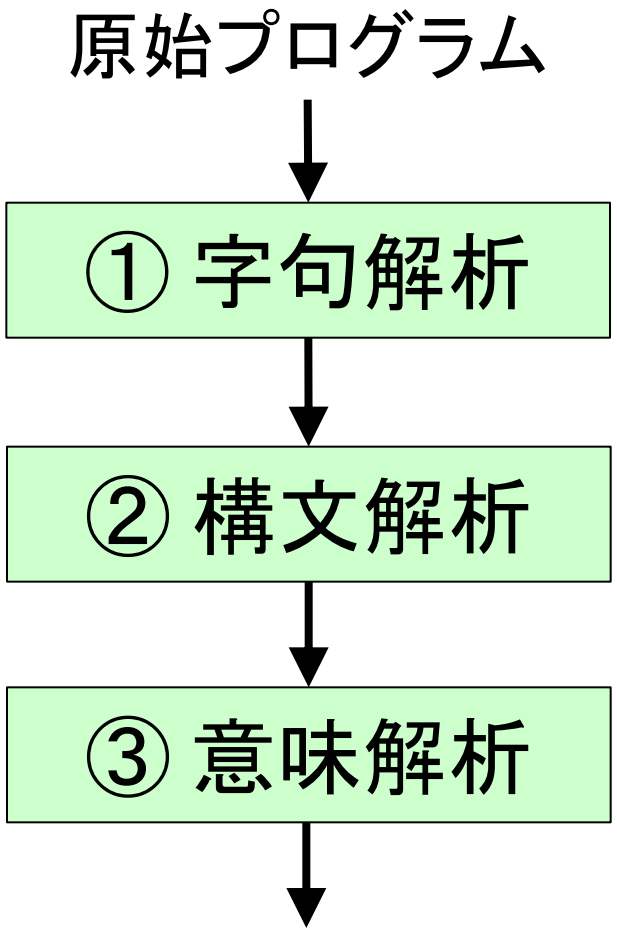
第7,8回 ③ 意味解析



第8回 ④ 文脈解析

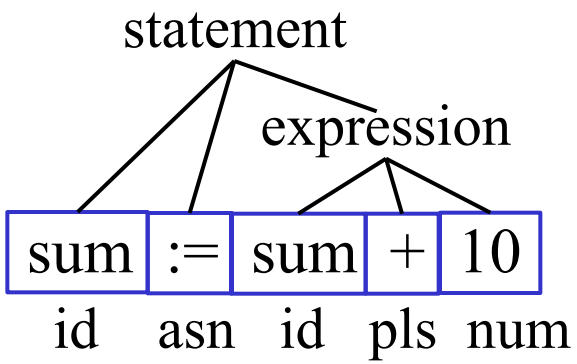
複数の文に
またがる処理

参考：コンパイラの解析処理



sum := sum + 10

sum	:=	sum	+	10
id	asn	id	pls	num



解析の各段階における処理内容

（形態素解析 ⇒ 構文解析 ⇒ 意味解析 ⇒ 文脈解析）

1. 入力文が正しいかどうか判定する

   （言語知識の一種である制約を用いる．例：文法）

2. 正しい場合，可能な解析結果を数え上げる

   （複数解が存在 ⇒ 曖昧性）

3. その中から妥当な結果を選択する

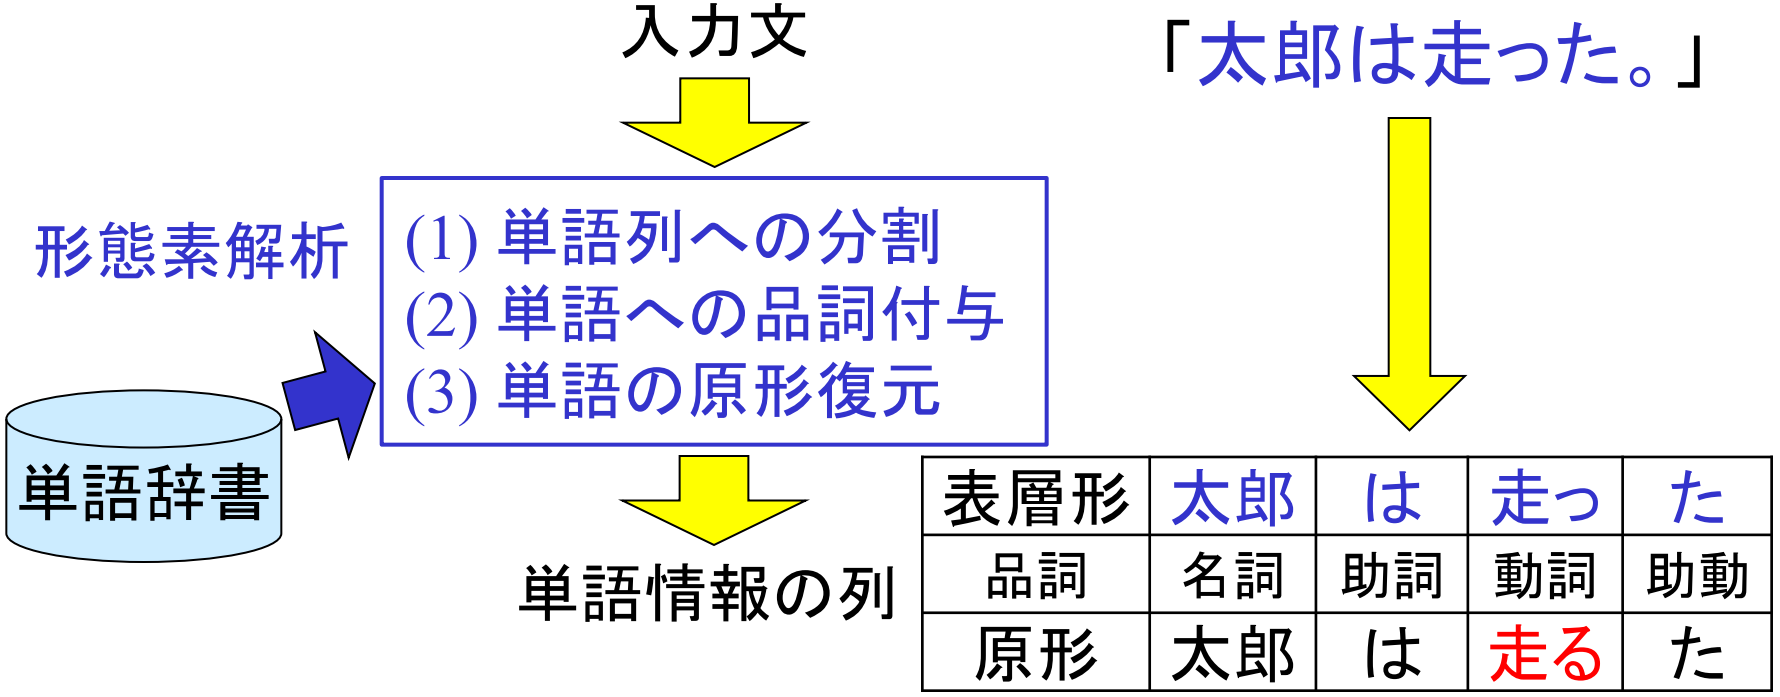
   （言語知識の一種である選好を用いる．例：出現確率）

解析処理の特徴と応用との関係

- 浅い解析（形態素解析）
  - 比較的，解析精度が高く，処理時間が短い
  - このレベルの解析のみで十分な応用も多い（例：情報検索）
- 深い解析（構文解析，意味解析，文脈解析）
  - 処理が表層から遠ざかるにつれて，解析精度が低くなり，処理時間が増大する
  - 応用によっては，このレベルの処理が求められる（例：文章理解，質問応答）

形態素解析（Morphological Analysis）

注：厳密には「形態素」≠「単語」だが，慣例にならい，
以後「形態素」という言葉の代わりに「単語」と言う



参考：英文解析の場合は，上記 (2) と (3) の処理が重要

参考：形態素解析を使ってできること

※形態素解析ツールMeCab は次回説明

- わかち書き処理

```
% mecab  -Owakati
秋刀魚が旨い
秋刀魚  が  旨い
```

- 読みへの変換

```
% mecab  -Oyomi
秋刀魚が旨い
サンマガウマイ
```

- 音声合成（の前処理）
- かな漢字変換
  （密接に関連する技術）

```
さんまがうまい
→  秋刀魚が旨い
```

単語辞書

単語辞書

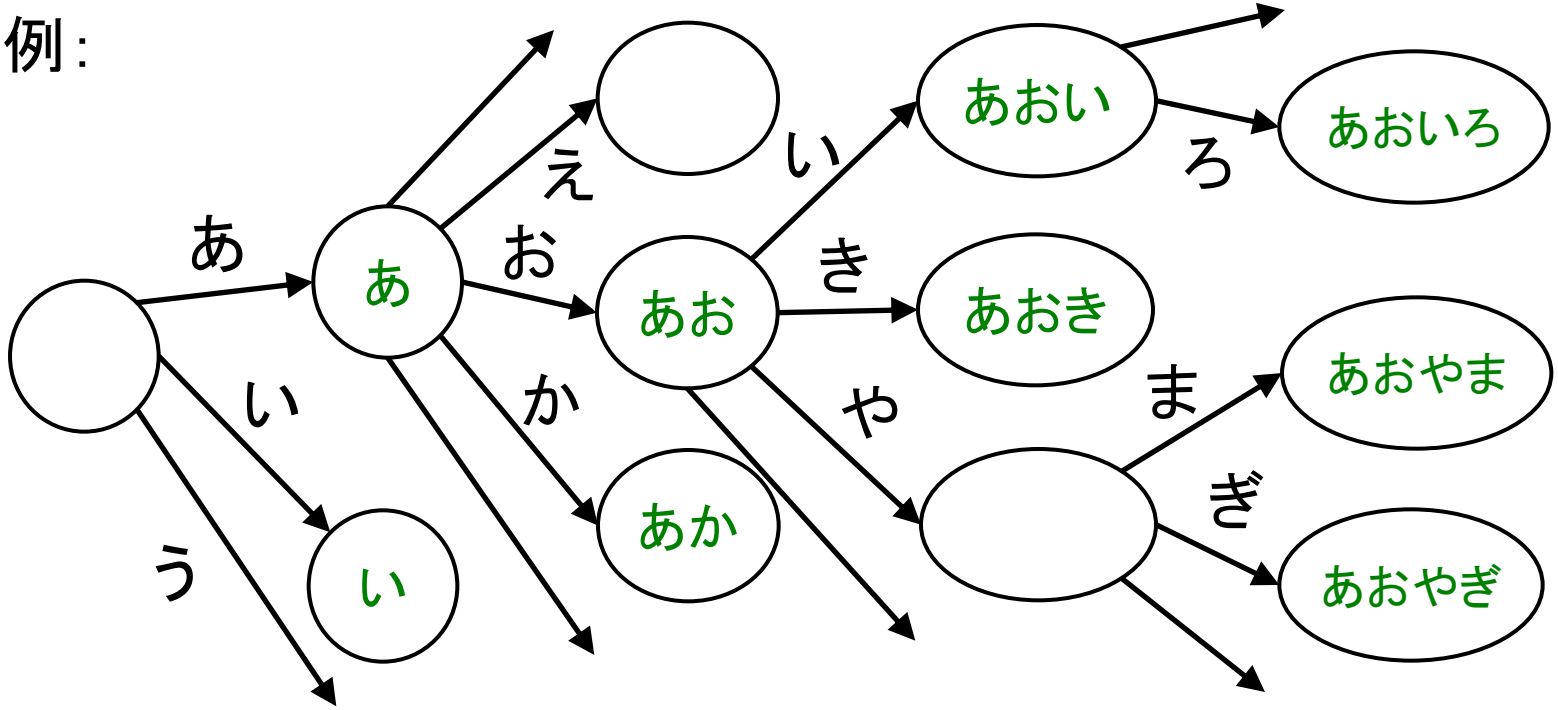
- 単語ごとに，形態情報・構文情報・意味情報を記述し，集めたもの
  - 形態素解析用の単語辞書には，意味情報は必ずしも含まれない
- 単語辞書のデータ例

（形態素解析ツール MeCab 付属の IPA辞書より）

表層形	原形	読み	品詞	活用型	活用形	コスト
本	本	ホン	名詞-一般	ー	ー	5947
読む	読む	ヨム	動詞-自立	マ行五段	基本形	6121
読ん	読む	ヨン	動詞-自立	マ行五段	連用タ	6093

単語辞書のデータ構造

- トライ（Trie）
  - 文字列の検索に適した，木構造型のデータ構造
  - 例：



  - 実装技術：ダブル配列（double array）など

形態素解析アルゴリズム
（コストを用いない方法）

問題の定式化

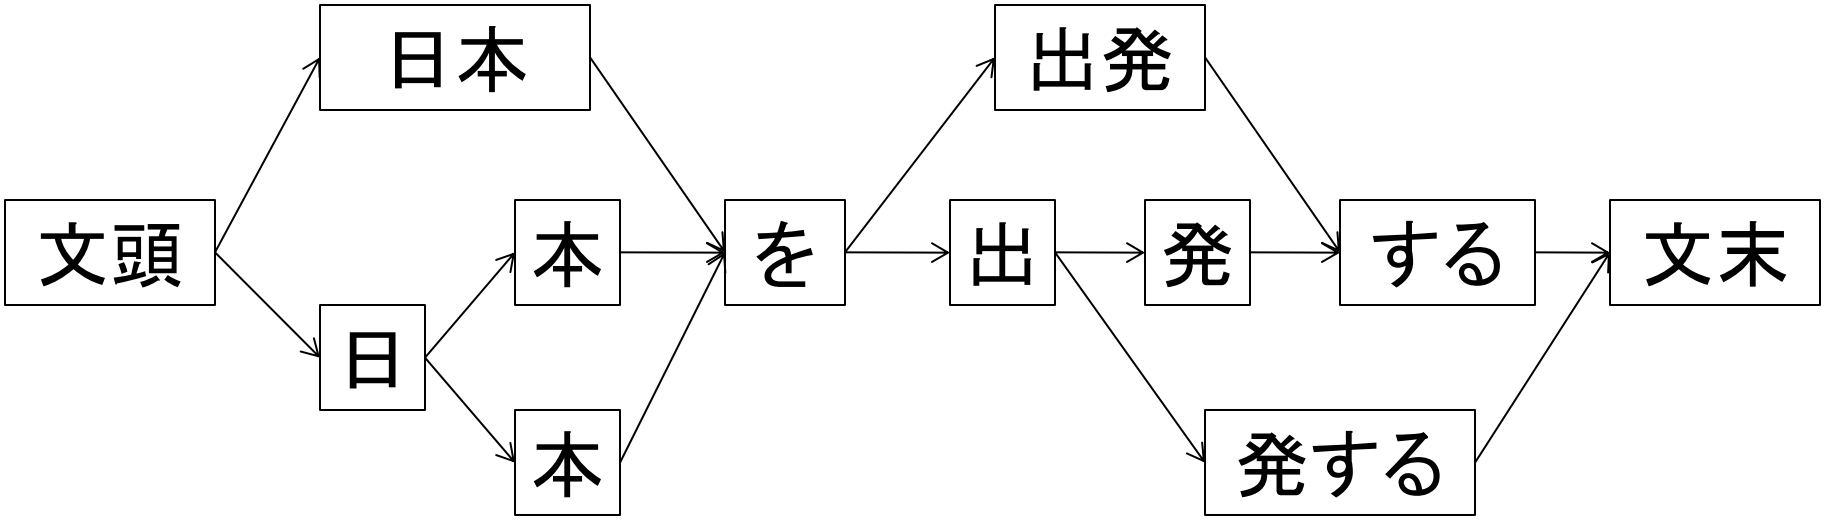
- まず，単語辞書を参照して，与えられた入力文を単語の列へ分割するあらゆる可能性を示すグラフ構造（lattice と呼ばれる）を作成する

- 例：「日本を出発する」
  - 単語辞書

日	名詞
本	名詞
本	接尾辞
日本	名詞
を	助詞

出（る）	動詞
発	接尾辞
出発	名詞
発する	動詞
する	動詞

解析グラフ(Lattice)



- 形態素解析とは，解析グラフにおいて，文頭から文末までたどる複数の経路の中から最適な経路を選ぶ処理

形態素解析における経験則（Heuristics）

（経験則：たいてい正しい結果が得られるが，常に正しいとは限らない）

- 最長一致法（Longest Match）
  - 文の先頭から解析を始めて，もし可能な単語が複数あるならば最長のものを選んで進めていく
  - 深さ優先探索に相当
- 分割数最小法
  - 文全体の単語数が最小となる分割を選ぶ
  - 文を構成する単語の平均長が最長のものを選ぶと見なせる

⇒ どちらの方法も，解析精度が十分でない

文例：「すももももももものうち」，「見たことある？」

形態素解析における制約：接続可能性

- 接続可能性行列
  - 例：

左＼右	名詞	接尾	助詞	動詞	文末
文頭	1	0	0	1	―
名詞	1	1	1	1	0
接尾	1	1	1	1	0
助詞	1	0	1	1	0
動詞	1	0	1	1	1

1：接続可能
0：接続不可能

  - 解析において，この制約を満たす経路のみに限定する
- 問題点
  1. 接続可能(1)の組合せの中にも，比較的接続しやすい・しにくいという程度の差が存在する
  2. 接続不可能(0)とされる組合せであっても，日常生活の中で例外的に使われる可能性は 0 ではない(助詞の省略など)

⇒ 1/0 の区別より細かい，数値的重み(コスト)の導入

形態素解析アルゴリズム
（コストを用いる方法）

接続コスト最小法

- 各単語および単語どうしの接続にコストを課す．
  合計コストが最小の単語分割を求めるのが目標

文 $S = w_1\ w_2\ \ldots\ w_n$ （w_i: 単語）

$$\begin{aligned}&\mathrm{cost}(w_1\ w_2\ \ldots\ w_n) = \\ &\quad \mathrm{cost}(w_1) + \mathrm{cost}(w_2) + \ldots + \mathrm{cost}(w_n) + \\ &\quad \mathrm{cost}(w_1,w_2) + \mathrm{cost}(w_2,w_3) + \ldots + \mathrm{cost}(w_{n-1},w_n)\end{aligned}$$

- 単語コスト　cost(w)
  - 単語 w の出現頻度が小さいほど大きな値とする
- 接続コスト　cost(w, w’)
  - 単語 w と w’ が接続しにくいほど大きな値とする

続き

- 他の手法との関係
  - 単語コストをすべて 1 とし，接続コストを 0 にする ⇒ 分割数最小法と一致
  - 接続不可能な単語の組合せは接続コスト無限大 ⇒ 接続可能性行列を用いる手法に対応
- 単語コスト，接続コストの設定方法
  - 直感に基づき手作業で設定するのは，かなり大変
  - 統計的モデルに基づくコスト導出（次回の授業で説明）
  - 単語間の接続コスト cost(w, w') を単語クラス（品詞など）t, t' 間の接続コスト cost(t, t') で代用することが多い
- 文全体のコスト算出時に，w_1 が文頭に来るコスト cost(文頭, w_1) や w_n が文末に来るコスト cost(w_n, 文末）を加えることもある

Lattice上でコスト最小の経路を求めるアルゴリズム

- Viterbi アルゴリズム（動的計画法の一種）
  - 概要：lattice の各頂点 w に対し，文頭からその頂点までの経路の合計コストの最小値 C(w) とその最小値を与える経路を求めて記録していく
  - 文頭から始めて，注目する文字位置 i を 1 つずつ右へ移動しながら，以下の処理を行う

文字位置 i から始まるそれぞれの単語 w に対して次を行う

$$C(w) = \min_{w'} \{ C(w') + \mathrm{cost}(w', w) \} + \mathrm{cost}(w)$$

ここで w’ は文字位置 i で終わる任意の単語とする

  - 最後に，lattice で文末を表す頂点に付与された合計コストの最小値に対応する経路が，求める経路である

参考：組合せ最適化問題と動的計画法

- 組合せ最適化問題（Combinatorial Optimization）
  - 有限個の要素の組合せで定義される最適化問題
    （最適レイアウト，最適スケジューリング，最適経路など）
- 動的計画法（Dynamic Programming）
  1. 問題から小さい部分問題を抽出し，それに対する最適解を求めて記録する
  2. その部分問題を少し拡張して得られる部分問題を生成し，それに対する最適解を，前段で求めた最適解を用いて求めて記録する
  3. これを繰り返し，最終的に元の問題の最適解を求める
- 例：Dijkstra法（最短経路探索）

解析例

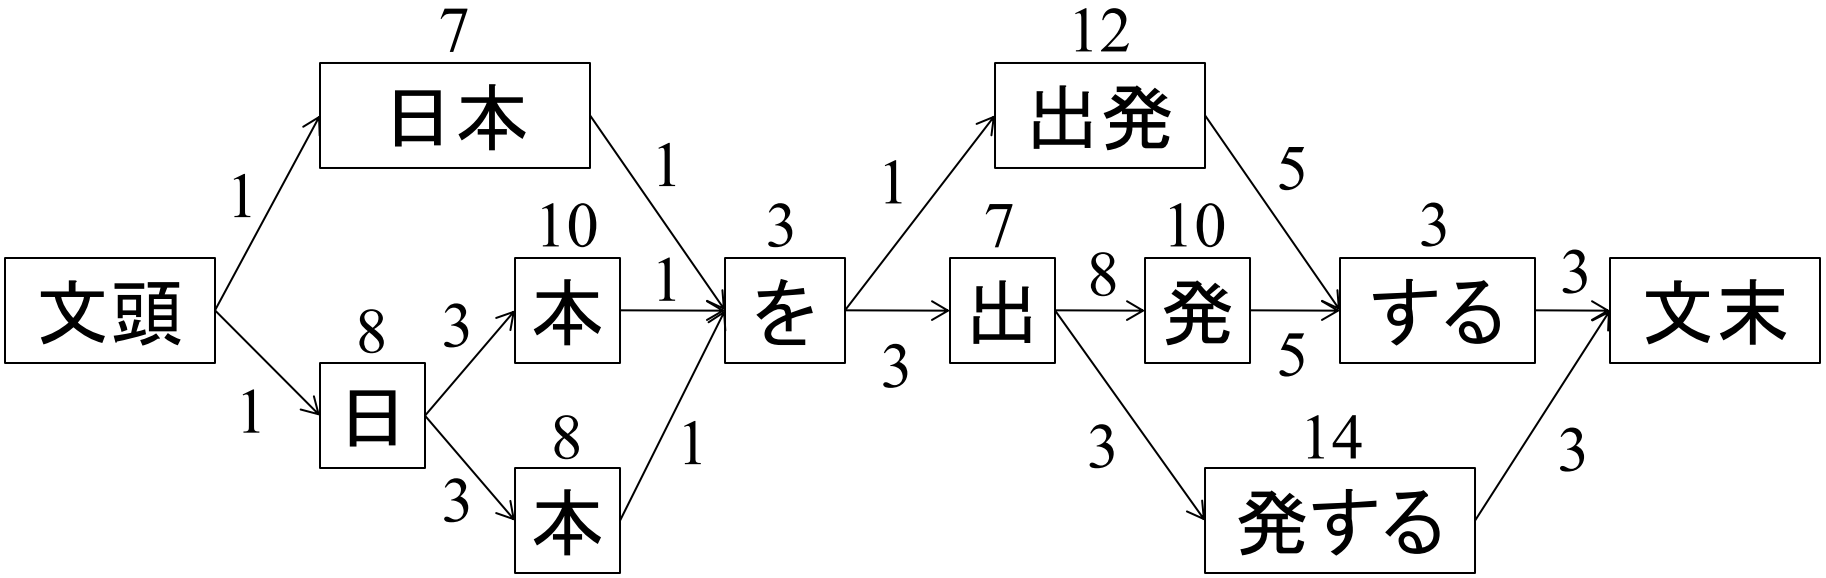
- 単語コスト

単語		コスト	単語		コスト
日	名詞	8	出(る)	動詞	7
本	名詞	10	発	接尾	10
本	接尾	8	出発	名詞	12
日本	名詞	7	発する	動詞	14
を	助詞	3	する	動詞	3

接続コスト

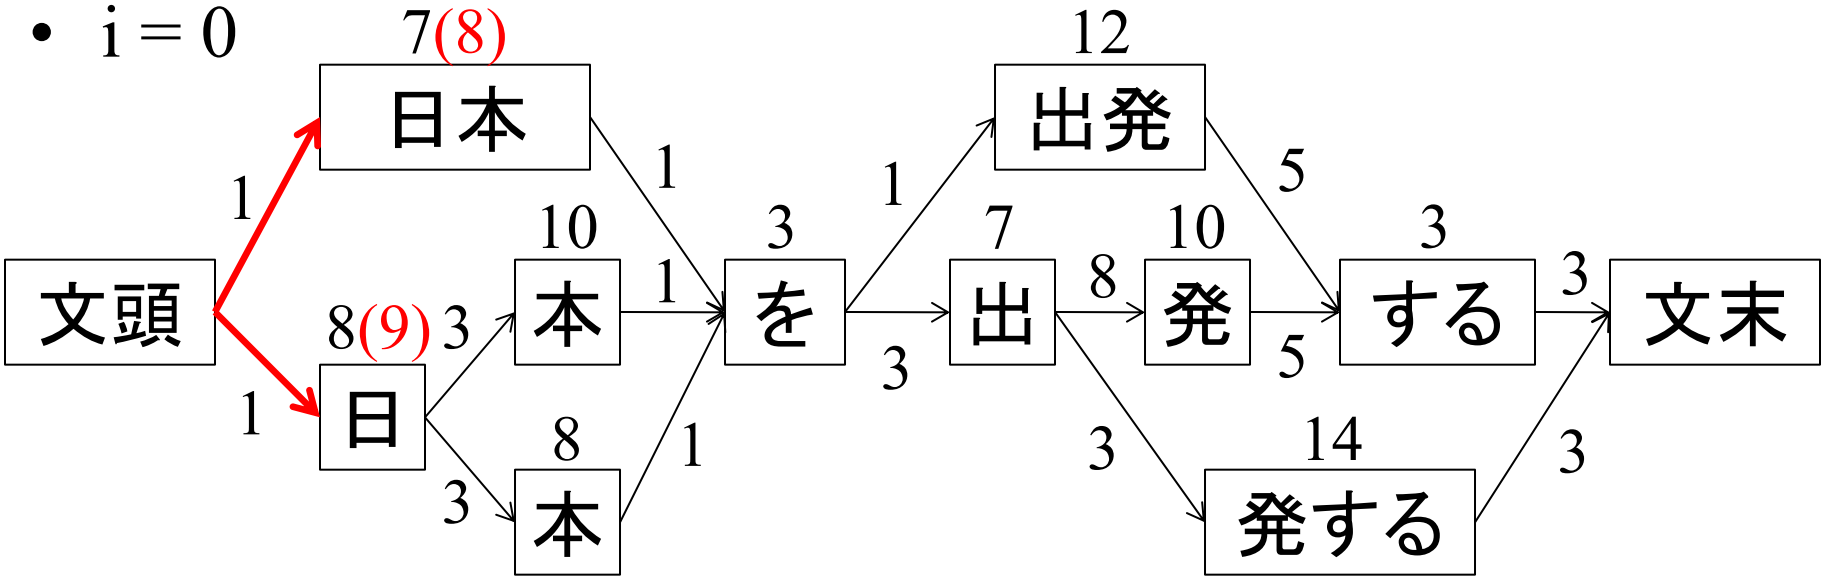
左＼右	名詞	接尾	助詞	動詞	文末
文頭	1	10	10	5	ー
名詞	3	3	1	5	10
接尾	3	5	1	5	10
助詞	1	10	5	3	8
動詞	3	8	3	3	3

- 解析グラフ(lattice)

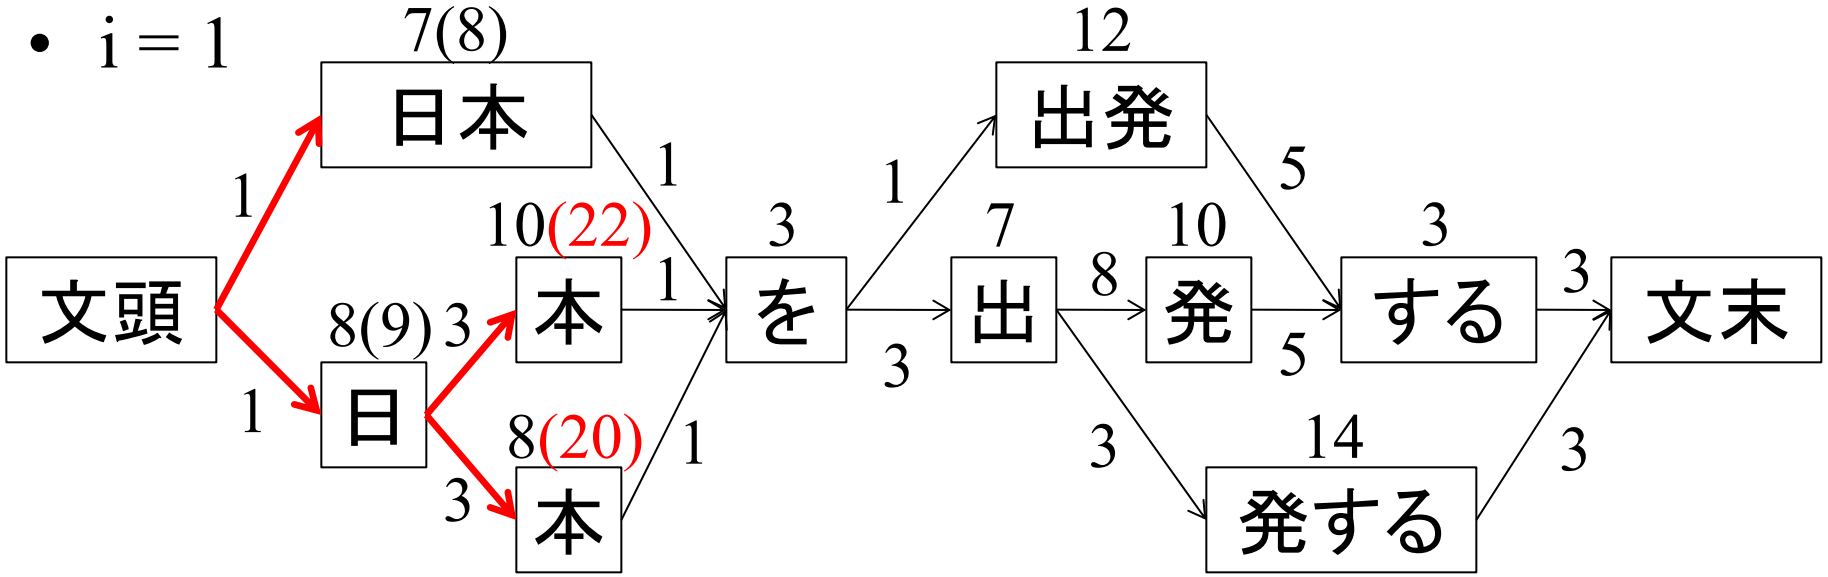


解析例(続き)

- i = 0

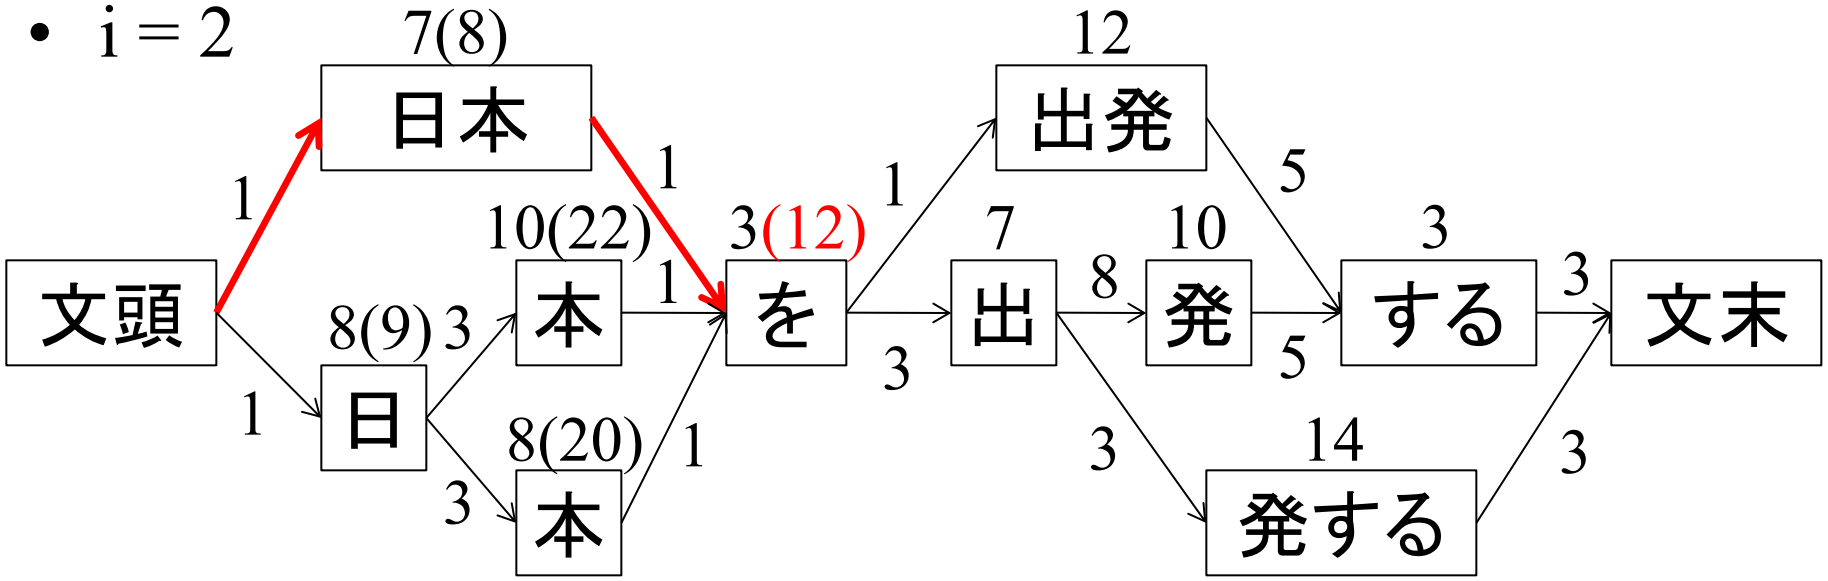

7(8)
日本
12
出発
1
1
5
10
3
7
10
3
文頭
8(9) 3
本
1
を
1
出
8
発
5
する
3
文末
日
3
1
1
3
8
14
3
本
発する

- i = 1

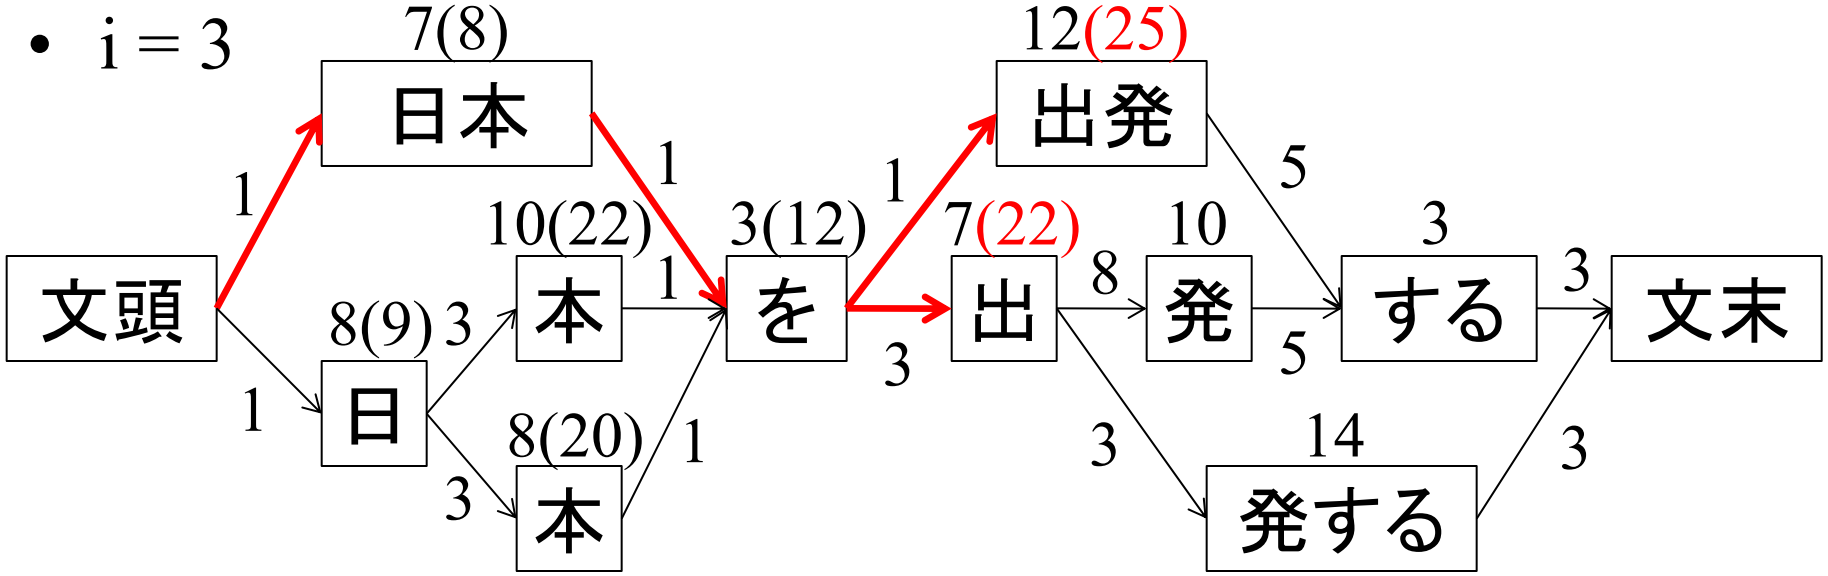

7(8)
日本
12
出発
1
1
5
10(22)
3
7
10
3
文頭
8(9) 3
本
1
を
1
出
8
発
5
する
3
文末
日
3
1
1
3
8(20)
14
3
本
発する

解析例（続き）

- i = 2

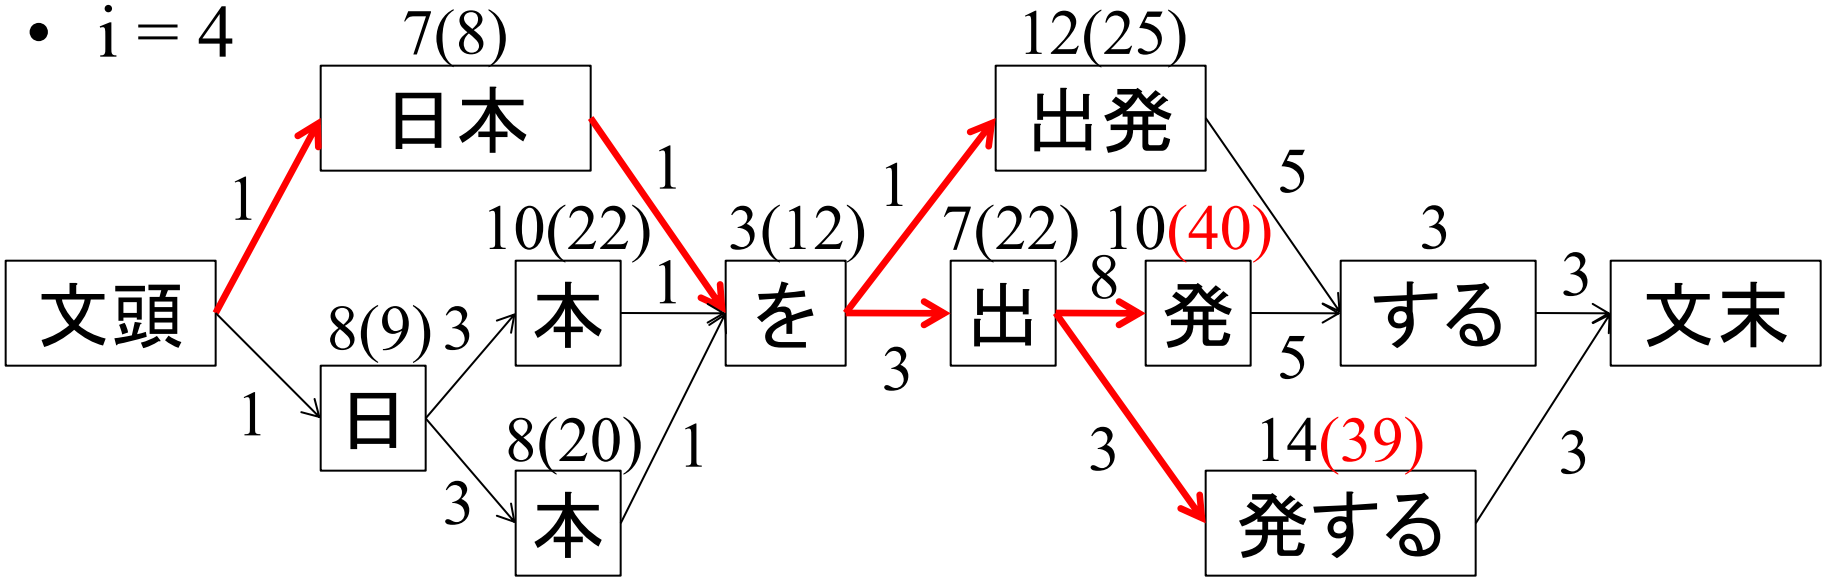

7(8)
日本
12
出発
1
1
1
5
10(22)
3(12)
7
10
3
文頭
8(9)
3
本
1
を
1
出
8
発
3
する
3
文末
1
日
3
1
5
8(20)
1
3
14
本
発する
3

- i = 3

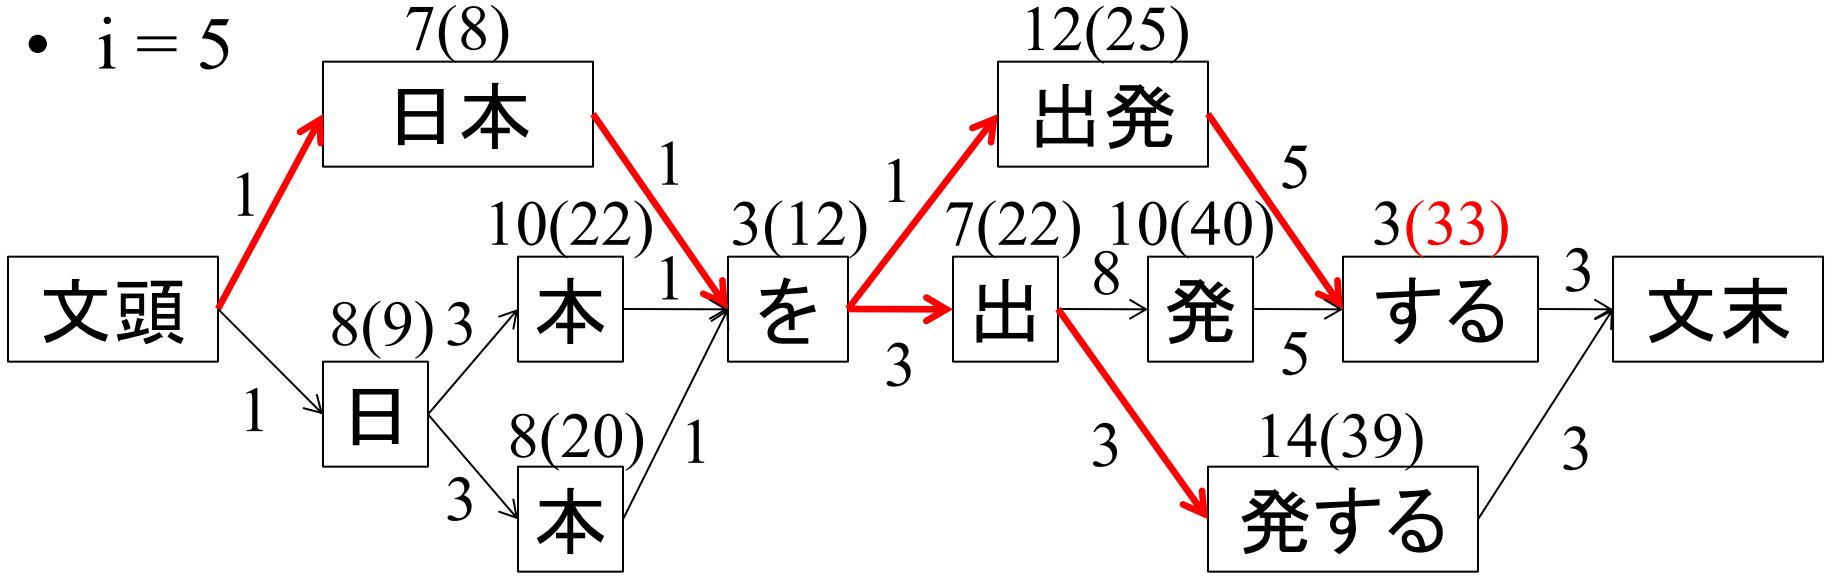

7(8)
日本
12(25)
出発
1
1
1
5
10(22)
3(12)
7(22)
10
3
文頭
8(9)
3
本
1
を
1
出
8
発
3
する
3
文末
1
日
3
1
5
8(20)
1
3
14
本
発する
3

解析例（続き）

- i = 4

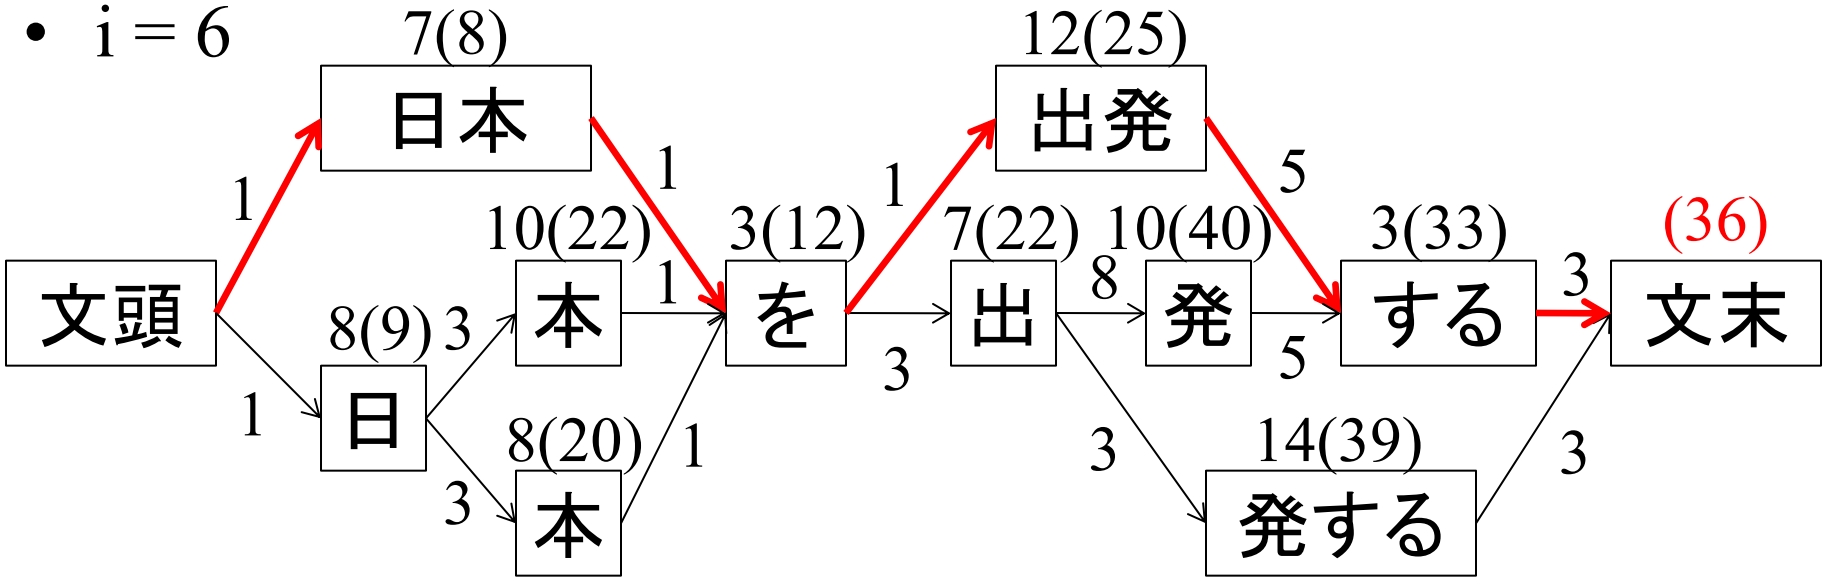

7(8)
日本
12(25)
出発
1
1
1
5
10(22)
3(12)
7(22)
10(40)
3
文頭
8(9)
3
本
1
を
1
出
8
発
5
する
3
文末
1
日
3
3
8(20)
1
14(39)
3
本
3
発する

- i = 5


7(8)
日本
12(25)
出発
1
1
1
5
10(22)
3(12)
7(22)
10(40)
3(33)
文頭
8(9)
3
本
1
を
1
出
8
発
5
する
3
文末
1
日
3
3
8(20)
1
14(39)
3
本
3
発する

解析例（続き）

- i = 6



- 赤線の経路が最小コストの経路（解析結果）となる

今日のまとめ

- 形態素解析(1)解析手法
  - 形態素解析の概要
  - 単語辞書
  - 形態素解析アルゴリズム(コストを用いない方法)
  - 形態素解析アルゴリズム(コストを用いる方法)

コストを用いる方法のほうが柔軟で，高い解析精度が期待できるが，コストの適切な割り当て方が課題となる

次回：形態素解析(2)コスト推定，関連技術

宿題（提出不要，解答は次回）

- 単語辞書，単語コスト，接続コストが以下のように与えられるとき，「すももももももです」という文をコスト最小法によって形態素解析しなさい．

- 単語辞書・コスト

表層形	品詞	コスト
すもも	名詞	12
もも	名詞	12
も	助詞	4
です	助動詞	4

接続コスト

左＼右	名詞	助詞	動詞	助動詞	文末
文頭	1	10	5	10	ー
名詞	3	1	5	5	10
助詞	1	5	3	10	8
動詞	3	3	3	1	3
助動詞	3	3	10	3	1

第2回課題　人名分類の実験
（詳細は前回のスライド参照）

- 課題1　人名分類の実行
  - 人名分類を複数の方法（Naive Bayes，SVMなど）で実行し，10分割交差確認により混同行列と正解率を求める
- 課題2　エラー分析
  - 課題1で行った実験のエラー分析を行う
- 課題3　特徴分析
  - 課題1で用いた各特徴のカテゴリによる偏りを調べる

（カテゴリごとの出現回数を数える，相互情報量を求める，など）

- 提出期限　10/28（水）夜までに ScombZに提出